



铁道学报

Journal of the China Railway Society

ISSN 1001-8360, CN 11-2104/U

《铁道学报》网络首发论文

题目：基于并行图卷积网络的无砟轨道监测测点异常识别
作者：孙立，郑凯亮，林超，黄永，李惠
收稿日期：2022-05-07
网络首发日期：2023-04-26
引用格式：孙立，郑凯亮，林超，黄永，李惠. 基于并行图卷积网络的无砟轨道监测测点异常识别[J/OL]. 铁道学报.
<https://kns.cnki.net/kcms/detail/11.2104.U.20230426.1324.002.html>



网络首发：在编辑部工作流程中，稿件从录用到出版要经历录用定稿、排版定稿、整期汇编定稿等阶段。录用定稿指内容已经确定，且通过同行评议、主编终审同意刊用的稿件。排版定稿指录用定稿按照期刊特定版式（包括网络呈现版式）排版后的稿件，可暂不确定出版年、卷、期和页码。整期汇编定稿指出版年、卷、期、页码均已确定的印刷或数字出版的整期汇编稿件。录用定稿网络首发稿件内容必须符合《出版管理条例》和《期刊出版管理规定》的有关规定；学术研究成果具有创新性、科学性和先进性，符合编辑部对刊文的录用要求，不存在学术不端行为及其他侵权行为；稿件内容应基本符合国家有关书刊编辑、出版的技术标准，正确使用和统一规范语言文字、符号、数字、外文字母、法定计量单位及地图标注等。为确保录用定稿网络首发的严肃性，录用定稿一经发布，不得修改论文题目、作者、机构名称和学术内容，只可基于编辑规范进行少量文字的修改。

出版确认：纸质期刊编辑部通过与《中国学术期刊（光盘版）》电子杂志社有限公司签约，在《中国学术期刊（网络版）》出版传播平台上创办与纸质期刊内容一致的网络版，以单篇或整期出版形式，在印刷出版之前刊发论文的录用定稿、排版定稿、整期汇编定稿。因为《中国学术期刊（网络版）》是国家新闻出版广电总局批准的网络连续型出版物（ISSN 2096-4188，CN 11-6037/Z），所以签约期刊的网络版上网络首发论文视为正式出版。

基于并行图卷积网络的无砟轨道监测测点异常识别

孙 立¹, 郑凯亮², 林 超¹, 黄 永², 李 惠²

(1. 中铁第四勘察设计院集团有限公司 线站处, 湖北 武汉 430063;
2. 哈尔滨工业大学 土木工程智能防灾减灾工信部重点实验室, 黑龙江 哈尔滨 150006)

摘 要:针对高速铁路无砟轨道结构健康监测在服役过程中可能出现由结构局部损伤或者传感器故障导致的测点异常问题, 建立一种并行图卷积神经网络模型, 应用于高速铁路无砟轨道监测测点异常的识别。利用结构早期初始状态的监测数据训练并行图卷积神经网络, 获得结构初始状态下的测点数据之间的空间关联性。利用并行图卷积神经网络预测服役状态无砟轨道测点监测数据, 实现轨道监测测点异常的识别。此外, 对于明显漂移的数据可基于有向图分析修正预测结果。本文将该方法应用于某高速铁路无砟轨道结构长期监测数据, 应用该模型识别了异常测点。

关键词: 图卷积神经网络; 无砟轨道; 结构健康监测; 异常识别; 状态评估

中图分类号: U216.3 文献标志码: A

Anomaly Detection of Structural Monitoring Points for High-Speed Railway Ballastless Track based on Parallel Graph Convolution Neural Network

SUN Li¹, JIA Kailiang², LIN Chao¹, HUANG Yong², LI Hui²

(1. Department of Railway Line and Station Survey and Design, China Railway Siyuan Survey and Design Group Co., Ltd., Wuhan 430063, China;
2. Key Lab of Smart Prevention and Mitigation of Civil Engineering Disasters of the Ministry of Industry and Information Technology, Harbin Institute of Technology, Harbin 150006, China)

Abstract: Aiming at the abnormal monitoring points in the structural health monitoring of high-speed railway ballastless track caused by local structural damage or sensor failure during service, a parallel graph convolution neural network model was established and applied to the anomaly detection of structural monitoring points of high-speed railway ballastless track. Using the monitoring data of the early initial state of the structure, the parallel graph convolution neural network was trained to obtain the spatial correlation among various monitoring points in the initial state of the structure. The parallel graph convolution neural network was then used to predict the monitoring data of ballastless track monitoring points in service, to realize the identification of abnormal monitoring points. In addition, for data with obvious drift, the prediction results can be corrected based on directed graph analysis. The method was also applied to the long-term monitoring data of ballastless track structure of high-speed railway, while the presented model was used to identify abnormal monitoring points.

Key words: graph convolution neural network; ballastless track; health monitoring; anomaly detection; condition assessment

高速铁路(以下简称“高铁”)轨道的结构状况关系着高速列车能否正常运营, 若存在安全隐患可能对旅客的生命安全、国家财产造成严重威胁^[1]。结构健康监测技术能够及时评估和预警结构的异常状态, 从而实现对

可能发生损伤的结构构件进行详细检查及维修, 最大程度避免大量财产损失^[2]。目前, 国内外研究者针对土木工程结构健康监测技术进行了大量研究^[3-4]。欧进萍等^[5]基于光纤拉断引起菲涅尔反射机理设计多段分布式光

收稿日期: 2022-05-07; 修回日期: 2022-09-09

基金项目: 中国铁建股份有限公司科技研发重大项目(2021-A03); 第七届青托工程(2021QNRC001)

第一作者: 孙 立(1969—), 男, 湖北麻城, 正高级工程师, 硕士。E-mail: 2430303903@qq.com

通信作者: 黄 永(1984—), 男, 湖南衡阳人, 教授, 博士。E-mail: huangyong@hit.edu.cn

纤维裂缝监测系统用于监测混凝土随机裂缝; 朱宏平等^[6]研究子结构与整体结构的关系, 提出大型复杂结构的健康体检方法; 李宏男等^[7]研究建立大桥拱桥监测系统, 并应用于沈阳伯官大桥; 罗尧治等^[8]研究设计雄安站屋盖结构无线健康监测系统, 并利用实际数据进行验证。相比传统的土木工程结构, 铁路设施的建设关系国计民生, 其安全性尤为重要。为更清楚地掌握服役铁路轨道状态, 研究者们进行了铁路轨道监测相关研究, 周洋等^[9]将网络链路拓扑结构转化为树形结构, 在指定位置设置监测传感器实现高铁故障链路定位; 冷伍明等^[10]研究既有重载铁路过渡段沉降监测数据, 分析沉降规律并利用模型预测差异沉降; 杜彦良等^[11]研究武汉长江大桥监测系统及评估系统, 并根据运行结果验证了系统的可靠性; 林超^[12]研究持续高温对 CRTSII 型板式无砟轨道温度场影响。高铁无砟轨道作为一种新型轨道形式, 为列车的高速行驶提供了必要条件, 且高速列车多为载客列车, 因此保证高铁无砟轨道运营安全尤为重要。然而, 动态大荷载高铁无砟轨道健康监测方法鲜有报道。

随着计算机科学和人工智能技术的发展, 具有提取图特征能力的图卷积神经网络被广泛应用于各个领域。王增光等^[13]基于图卷积神经网络实现了短期交通速度的预测; 曾筠程等^[14]将图卷积神经网络与长短期记忆网络和注意力机制结合利用时空特征建立预测模型, 实现了短时交通速度预测; 杨光泽等^[15]基于图卷积网络建立有向图嵌入的自注意力模型, 建立了毕业去向预测方法; 张刘超等^[16]研究图卷积神经网络在组学数据分类的预测效能, 通过对比验证了图卷积神经网络在组学数据分类存在的巨大潜力; Guo 等^[17]利用时空数据训练学习并优化图卷积神经网络, 实现对交通运输量的预测; Geng 等^[18]将不同的区域关系建模为多个图, 通过多图卷积网络的显式建模实现了对出租车需求量的预测; 李顺龙等^[19]通过研究 Graph WaveNet^[20], 利用数据之间的时空相关性提出一种斜拉桥异常监测数据检测方法。

针对高铁无砟轨道状态监测, 本文提出一种基于并行图卷积神经网络的高铁轨道异常监测测点识别方法, 利用图卷积神经网络学习传感器各测点之间的空间关联性, 根据空间关联性预测传感器测量结果, 进而判断测点数据是否异常。本文提出的方法基于对数据的评估, 可以实现对高铁无砟轨道结构健康状况评估的目的。

1 并行图卷积神经网络模型

结构同一区域的传感器测点之间往往存在较强的空间关联性, 利用不同测点之间的关联性可以实现对监测数据的预测, 根据预测与实测数据的差异可实现测点异常识别的目的。然而, 若用于预测的测点数据存在异

常, 异常的输入造成图卷积神经网络预测不准确进而影响对其他测点的预测准确性。本文提出一种并行图卷积神经网络模型用于监测测点的预测, 该方法通过分散预测输出对输入测点的依赖降低了局部异常数据对图卷积神经网络预测结果的影响, 且多个并行图卷积神经网络可有效提高预测精度。

1.1 可学习邻接矩阵的并行图卷积层

本文提出的并行图卷积神经网络包含 M 个并行的图卷积层, 每个图卷积层均参与学习不同测点之间的空间关联性。每个图卷积层均采用可学习邻接矩阵对各测点数据进行卷积运算, 多个并行的图卷积神经网络的卷积运算结果在融合层融合得到预测结果的标准值, 每个并行的图卷积层为

$$\mathbf{Z}_l^{(l)} = \mathbf{A}^{(l)} \mathbf{X}_l + \mathbf{b}_l \quad (1)$$

式中: $\mathbf{Z}_l^{(l)}$ 为第 l 个图卷积层卷积运算的中间结果, $l=1, 2, \dots, M$, t 为对应的时刻序号; $\mathbf{A}^{(l)}$ 为第 l 个并行图卷积层的可学习邻接矩阵 $\mathbf{A}^{(l)}$ 对其进行归一化处理; $\mathbf{X}_l = [\bar{x}_{1,t}, \bar{x}_{2,t}, \dots, \bar{x}_{N,t}]^T \in \mathbb{R}^N$ 为标准化后各个并列的图卷积层的数据输入; \mathbf{b}_l 为第 l 个图卷积层的偏置, 为可学习的参数, $\mathbf{b}_l \in \mathbb{R}^N$ 。

1.2 图卷积神经网络架构

并行图卷积神经网络结构见图 1, 其中 $M=12$ 。12 个卷积运算结果 $\mathbf{Z}_1^{(1)}, \mathbf{Z}_1^{(2)}, \dots, \mathbf{Z}_1^{(12)}$ 在融合层进行非线性处理后再融合, 多个激活函数分别对各个图卷积层计算的中间结果进行非线性处理, 提升了算法的非线性预测能力。

注意到图卷积层个数 M 的取值和模型预测精度及计算复杂度紧密相关。试验结果表明: M 取值越大, 预测越精确, 但是相应耗时会越多。此外, M 增大到一定程度后, 继续增大, 模型预测结果提升效果并不明显。因此, 综合考虑预测精度和计算效率等因素, 本文将 M 取值为 12。

图卷积运算过程如下:

(1) 输入标准化的数据 \mathbf{X}_l 分别至 12 个图卷积层中, 根据式 (1) 进行卷积运算, 得到图卷积运算结果 $\mathbf{Z}_1^{(1)}, \mathbf{Z}_1^{(2)}, \dots, \mathbf{Z}_1^{(12)}$ 。

(2) 12 个图卷积层与其权重系数相乘在融合层利用 \tanh 激活函数非线性处理, 再对各个非线性处理后的结果累加作为标准化的预测值, 融合层为

$$\hat{\mathbf{X}}_l = \sum_{l=1}^{12} \tanh(k_l \mathbf{Z}_l^{(l)}) \quad (2)$$

式中: $\hat{\mathbf{X}}_l$ 为并行图卷积神经网络预测输出的标准值; k_l 为第 l 个图卷积层运算结果的组合系数, 由训练得到。

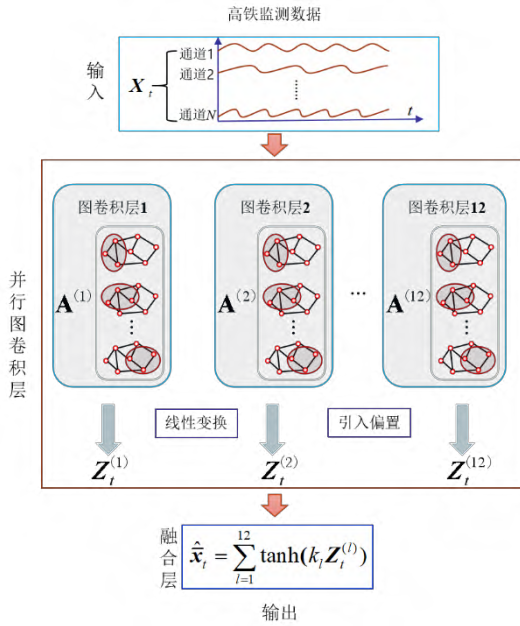


图1 并行图卷积网络结构

1.3 损失函数和惩罚项

利用传感器采集的早期初始状态的监测数据训练图卷积神经网络，训练过程采用 MSE 损失函数为

$$L = \sum_{i=1}^m \left| X_t - \hat{X}_t \right|^2 \quad (3)$$

式中： m 为批量训练数据量的大小。

若模型预测时自身结点信息对自身结点进行预测贡献过多时，模型不能有效的学习不同传感器测点之间的空间关联性，会降低预测结果的准确性。为尽可能降低或者避免这种现象，引入惩罚项 R

$$R = \sum_{l=1}^{12} \lambda_l \cdot \text{tr}(A^{(l)}) \quad (4)$$

式中： $\text{tr}(\cdot)$ 为矩阵的迹； $\lambda_l (l=1, 2, \dots, 12)$ 为第 l 个图卷积神经网络邻接矩阵主对角线元素的惩罚项系数，其值越大，邻接矩阵主对角线元素参与预测的作用越小。

引入惩罚项 R 后的并行图卷积神经网络模型的损失函数为

$$L_u = \sum_{i=1}^m \left| X_t - \hat{X}_t \right|^2 + R \quad (5)$$

1.4 并行图卷积神经网络的特点

并行图卷积神经网络模型采用图1所示的12个并行的图卷积层，以及其后的融合层。并行图卷积神经网络具有以下优点：

(1) 每个图卷积层均采用 \tanh 激活函数的非线性处理，增加了模型对非线性映射关系的预测能力。

(2) 利用多个并行邻接矩阵进行图卷积运算，每个不同的图卷积层提取图关系的特征不同，多个图卷积层

运算结果融合后使得模型具有更准确的预测能力。

(3) 单个的图卷积邻接矩阵较为稀疏，预测结果对单个节点的依赖较大，权重相对集中，若被依赖节点异常则会影响预测结果。多个并行图卷积层融合后的预测结果并不强烈依赖少数结点，邻接矩阵权重相对分散，单个测点异常不会对预测输出造成明显影响，这在后面3.2节的结果中也会有展示。

2 无砟轨道监测测点异常识别方法

利用可学习邻接矩阵的并行图卷积网络对高铁无砟轨道结构监测测点之间的空间关联性进行建模。结构早期状态相对完好且监测系统性能良好，因此采用监测系统早期采集的数据训练并行图卷积神经网络模型。并使用训练后的模型预测后续监测数据，通过实测数据以及预测数据的对比判断轨道监测数据的异常情况，进而识别结构测点异常状态。若数据中出现明显漂移现象，则根据预测模型学习得到的空间关联性建立有向图，消除漂移数据的影响，更新预测数据，实现更准确的高铁轨道结构状态评估。

2.1 空间关联性建模与数据预处理

通常情况下，结构健康监测系统由多个测点组成，且测点数据间可能存在较强的非线性关系，仅分析结构两两测点数据之间的空间关联性不能够准确描述其关系且造成其他有关联性数据测点的浪费。因此本节利用基于并行图卷积神经网络建立结构健康监测测点数据异常识别方法，将监测测点建模为有向图上的结点，利用早期数据训练图卷积神经网络，对结点的关联性进行空间关系建模。训练后的模型用于预测后续监测数据，根据预测数据与测量数据的差异诊断监测数据。

预测某一个监测测点时需要利用同一时间的其他测点数据，因此将同一时间的所有测点数据合并一组数据样本。为避免信息缺失以及数据质差的影响，将缺失数据的数据点、超过3倍数据标准差范围的数据点剔除，得到筛选后的数据用作数据异常识别。

同一时刻不同测点的数据进行标准化，获得 t 时刻标准化后的 N 个测点的数据 $\bar{x}_{n,t} \in X_t (n=1, 2, \dots, N)$ 为

$$\bar{x}_{n,t} = \frac{x_{n,t} - \mu_n}{\sigma_n} \quad (6)$$

式中： $x_{n,t}$ 为测点 n 对应的传感器在时间 t 所采集的数据； μ_n 为测点 n 各个时间段测得的 $x_{n,t}$ 的均值； σ_n 为测点 n 在各个时间段测得的 $x_{n,t}$ 的方差。

相反，通过式(6)标准化的逆变换，可由预测值的标准值 $\hat{\bar{X}}_t$ 变换得到预测值 \hat{X}_t 。

2.2 监测测点异常识别

经过训练后可获得12个并行的图卷积神经网络的

邻接矩阵 $A^{(1)}, A^{(2)}, \dots, A^{(12)}$ 以及每个图卷积层对应的权重 k_1, k_2, \dots, k_{12} 。模型预测数据和实测值对比结果可分为 3 类: 数据正常、数据异常、明显漂移 (明显异常)。正常数据和异常数据的区别在于残差是否过大, 而明显漂移数据则是整体数据的大范围漂移。利用 12 个图卷积层的计算结果进行融合得到预测值, 因此预测输出不会过分依赖某一个测点的数据, 在数据没有明显漂移的情况下, 单个测点的异常数据对网络预测结果不会产生较大影响。

结构测点异常识别的流程见图 2。具体步骤如下:

(1) 对传感器采集的数据进行预处理, 删除异常值, 利用预处理后的数据以时间顺序按照 1: 2 划分训练集和预测集, 将训练集前 1/3 数据视为早期结构完好状态, 后 2/3 数据作为后期服役状态数据, 用来诊断结构或健康监测系统是否出现异常。

(2) 建立包含 12 个并行图卷积神经网络的预测模型。利用训练集数据训练网络模型, 学习不同测点之间的空间关联性。

(3) 预测集数据经过标准化处理后输入并行图卷积神经网络模型得到预测输出的标准值, 并将其进行逆标准化变换得到预测输出。

(4) 对比实测值和预测值, 实现无砟轨道监测数据的异常诊断。若实测值与预测值趋势无偏差, 可认为各测点无异常; 如果某些传感器测点有偏差则认为局部测点异常, 建议检查无砟轨道监测区域, 确定是否为结构局部损伤; 若预测输出和测量值存在明显漂移, 则可利用有向图进行分析, 修正预测结果。

以异常节点为中心建立有向图分析方法为: 模型训练完成后, 将后续的实测数据输入到网络得到预测数据, 将预测数据与实测数据明显漂移的测点视为异常测点。以明显漂移结点为中心结点根据加权邻接矩阵 A_m 建立有向图。

按照上述方式建立的有向图表示明显漂移结点对其他结点预测的影响。加权邻接矩阵 A_m 为

$$A_m = \frac{\sum_{l=1}^{12} k_l A^{(l)}}{\sum_{l=1}^{12} k_l} \quad (7)$$

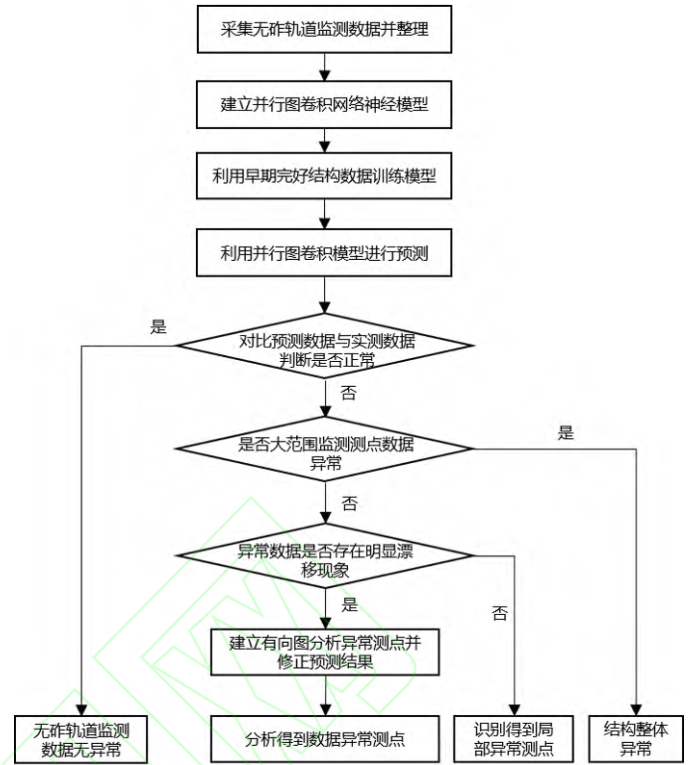


图 2 结构监测测点异常识别步骤

本方法对于同一区域的传感器网络, 当测点冗余度较高时, 测点数据的预测可以达到较高的精度。

3 工程数据验证

本文数据来源于某高铁无砟轨道监测工点, 采集 2015—2017 年无砟轨道应变监测数据, 应变测量传感器为 23 个, 编号为 1~23, 无砟轨道监测系统见图 3。对于路基地段, 应变测点在图 4 ②、③、④、⑤号轨道板板中及板端对应钢轨位置设置, 共 7 处, 其中某应变监测测点见图 3。对于桥梁地段, 应变测点在图 5 的“32 m 连续梁—2”的①、④、⑦号轨道板板中及板端共设置 9 处, 并在“32 m 连续梁—1”的①、③、⑤号轨道板板端和“32 m 连续梁—3”的①、③、⑤、⑦号轨道板板端共设置 7 处。



(a) 无砟轨道监测测点

(b) 结构应变传感器

图 3 无砟轨道监测系统




图4 路基地段无砟无缝线路应变测试图 (其中红色三角形为应变测点位置)

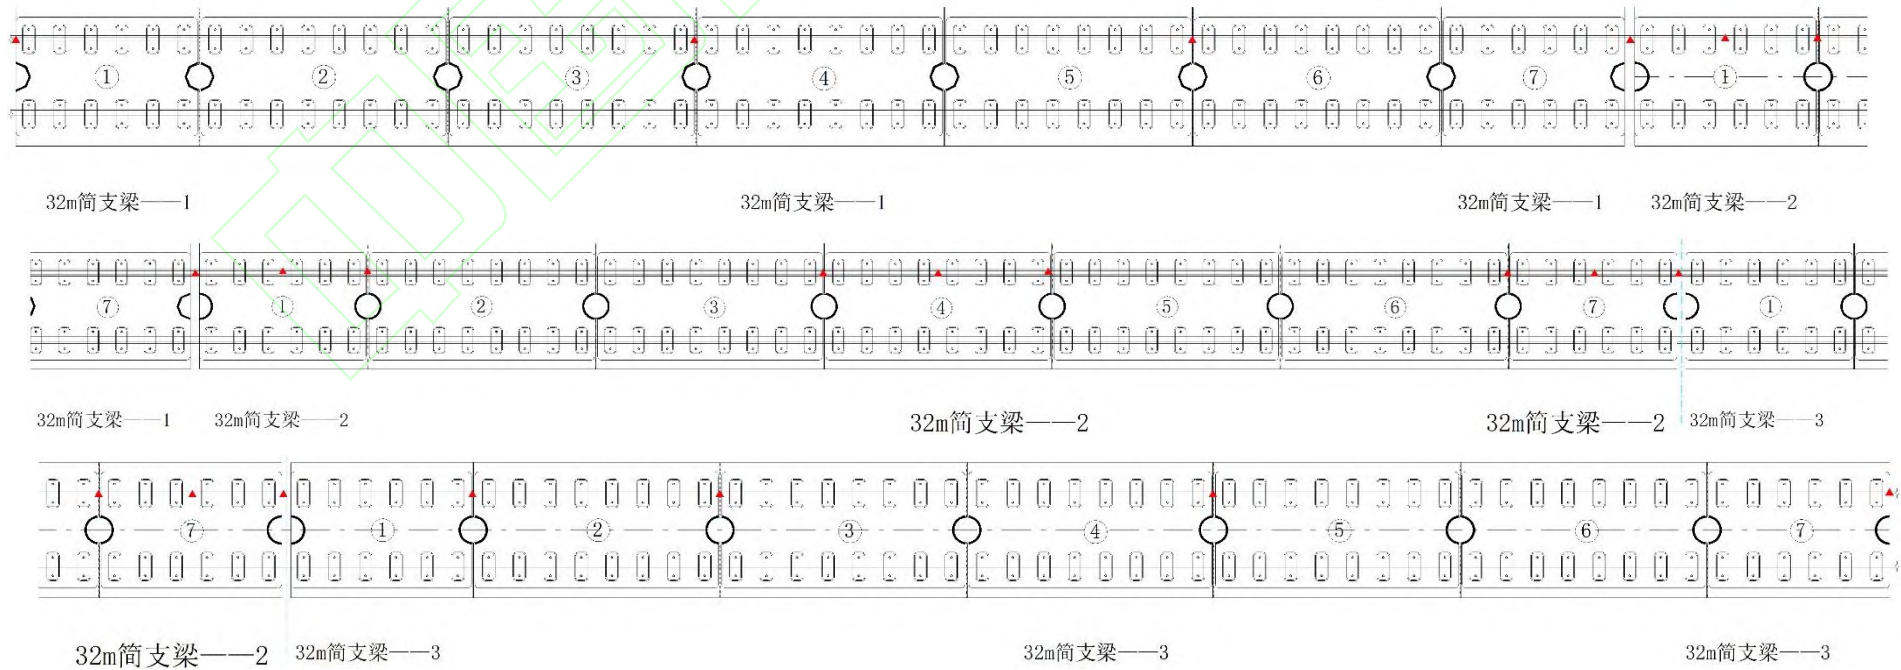


图5 桥梁地段无砟无缝线路应变测试图 (其中红色三角形为应变测点位置)

3.1 数据预处理及网络模型建立

将同一时间段的 23 个通道的数据合并作为单个样本, 剔除异常数据, 共有可用数据样本 75 907 组, 其中 2015 年 3 月 26 日—12 月 31 日的 29 745 组数据作为训练数据, 2016 年 1 月 1 日—2017 年 2 月 28 日的 46 162 组数据作为预测数据集。模型学习率设置为 0.001, 图卷积神经网络邻接矩阵主对角线元素的惩罚项系数给定 $\lambda_l=0.1$, ($l=1,2,\dots,12$), 单次训练样本批量大小为 64, 训练回合为 500。

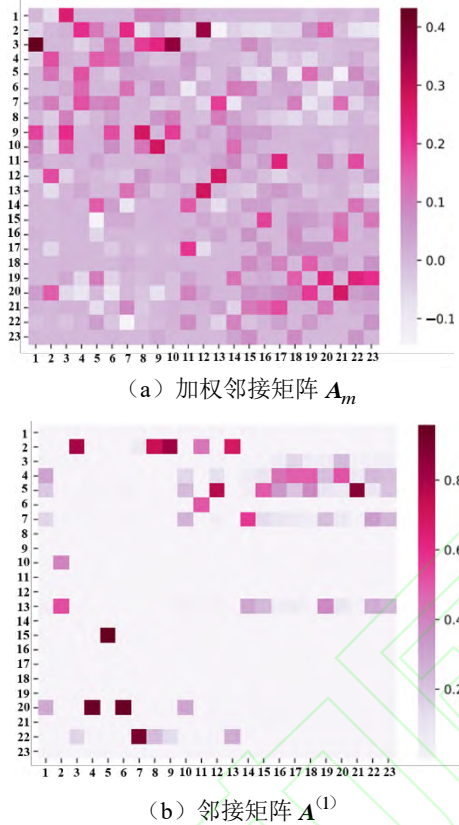


图6 加权邻接矩阵和单层邻接矩阵

3.2 测点异常识别结果

利用 2015 年 3 月 26 日—12 月 30 日的数据训练并行图卷积网络模型, 使模型学习到早期无砟轨道的不同传感器测点数据之间的空间关系。结构空间关系用图 6(a) 中的加权邻接矩阵表示, 其元素值大小表示不同测点间的预测权重。为了对比, 单个的图卷积邻接矩阵 $A^{(1)}$ 如图 6(b) 所示。可以看出, 显而易见, A_m 相较于 $A^{(1)}$ 更加分散, 即多个并行图卷积层融合后的预测结果并不强烈依赖少数结点, 这也是并行图卷积网络结构的优势。如果结构无损伤且传感器监测传感器未发生故障, 邻接矩阵表征的各个测点数据之间的关联性不会改变; 否则, 图卷积神经网络的预测结果和实测值会出现偏差。模型训练完成后, 将所有时间的数据样本输入模型, 得到包含所有结点的预测结果, 无异常测点的数据实量值与预测值见图 7, 异常测点的数据实测值和预测值见图 8。对比预测值和实测值, 其中大部分测点预测值与实测值趋

势一致, 少数几个测量通道在数据的时间后期出现了预测值与实测值偏差的情况。图 7 中预测值和实测值吻合度很好, 可以认为对应的传感器和结构局部位位置均没有异常。图 8 中传感器测点预测值和实测值在早期 (2016 年 12 月 31 日之前, 为模型训练阶段) 吻合较好, 传感器 2 和 6 的后期监测数据 (模型测试阶段) 预测值和实测值两者发生了较明显偏差。下面通过加权邻接矩阵对此两个测点进行进一步分析。

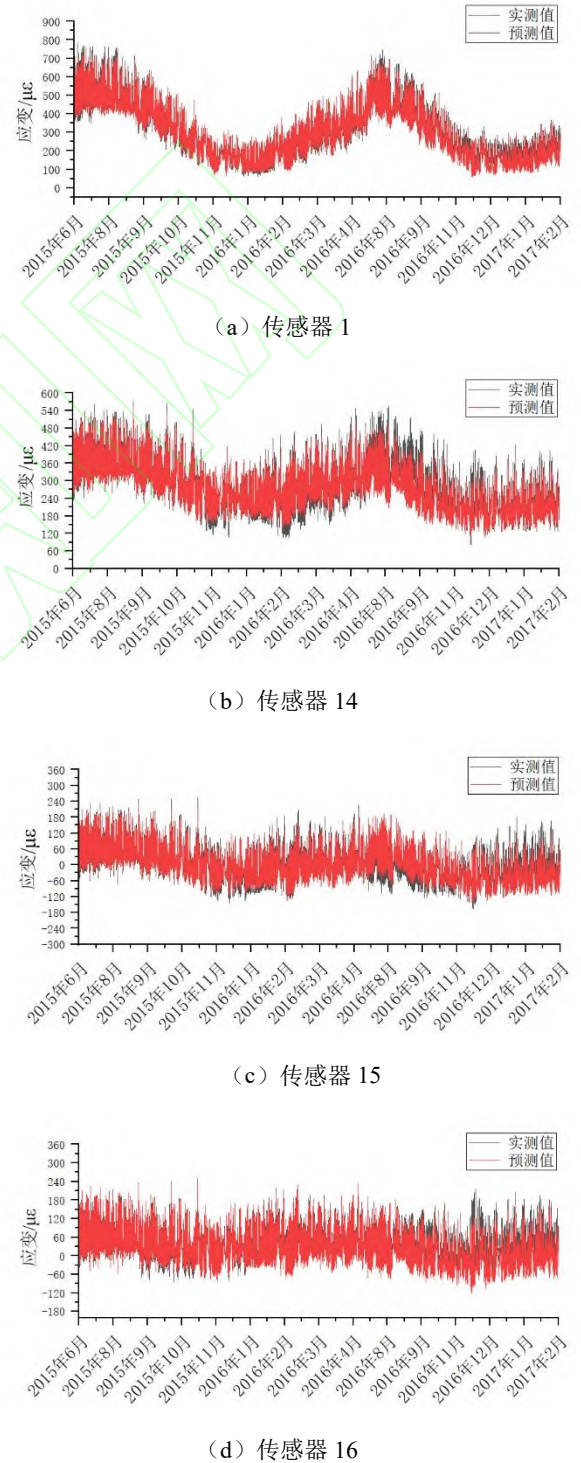




图7 无异常测点的数据实量值与预测值



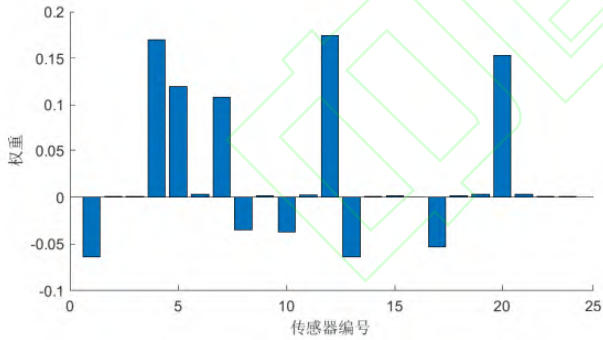
(a) 传感器 2




(b) 传感器 6

图 8 异常测点的数据实测值和预测值

根据加权邻接矩阵可以得到预测传感器 2 和 6 数据对应各传感器的权重见图 9。可以看出, 传感器受到多个测点影响, 并没有对某一个测点过分依赖, 因此测点出现非明显漂移情况对预测影响较小。此外, 可以推断传感器 2 和传感器 6 等测点在服役阶段出现异常, 其结果可能是局部结构异常或传感器故障, 可根据此诊断结果对局部区域进行检查。



(a) 传感器 2




(b) 传感器 6


图 9 预测传感器 2 和 6 数据对应各传感器的权重

4 有向图在消除漂移数据影响的应用

监测系统的传感器在役过程中往往会出现数据漂移现象, 可能是传感器出现故障等问题引起。为了研究有向图分析在消除漂移数据影响的应用, 且考虑到本文所利用的实际数据集并无测点数据明显漂移现象, 制造漂移数据进行研究。通道 3 实测数据和制造漂移数据见图 10, 传感器 3 实测数据与预测数据见图 10 (a), 在其他测点无偏移现象情况下, 此测点预测数据无偏移现象。将传感器 3 的监测数据在第 50 000 个数据点后的所有数据点的数值增加 1 000 作为漂移数据, 传感器 3 制造的漂移数据见图 10 (b)。注意到构造漂移数据的目的是研究有向图在消除漂移数据影响的应用潜力, 模拟的漂移数据不一定完全符合实际, 将来对于实际的漂移数据可进一步深入研究。



(a) 传感器 3 实测数据与预测数据



(b) 传感器 3 制造的漂移数据

图 10 通道 3 实测数据和制造漂移数据

根据加权邻接矩阵可以获得传感器 3 数据对其他测点数据的预测权重见如图 11。有图 11 可知传感器 3 对 1、6、8、9 和 10 号传感器的预测权重较大, 且权重均为正, 传感器 3 漂移数据输入网络模型后其他测点的预测结果见图 12。可以看出 2 个传感器测点数据的残差 (预测值与实测值之差) 为正, 实际上传感器 8、9 和 10 的预测输出结果与此类似。异常节点为中心节点的有向图见图 13, 为第 50 000 个数据样本点之后的数据利用并行图卷积神经网络预测输出和监测数据计算得到的残差以异常传感器 3 为中心节点的有向图。图 13 中红色节点表示残差为正, 蓝色节点表示残差为负。箭头的方向表示节点之间预测关系, 图中箭头表示传感器 3 测

量数据对传感器 1、6、8、9 和 10 的预测输出有影响。有向图中可以看出中心节点和其相邻节点残差正负号相反, 且传感器 3 对传感器 1、6、8、9 和 10 预测影响权重为正(影响权重即为图 6 的加权邻接矩阵的元素), 所以可以判断残差为正的 5 个传感器测点受到了传感器 3 的明显漂移数据影响产生的偏差。这是因为 3 号传感器漂移数据整体增大, 残差为负; 传感器 3 漂移数据以较大权重参与预测的传感器 1、6、8、9 和 10 的预测输出则会随着通道 3 的正向漂移而大于实测数据, 残差为正。根据有向图和测点残差可推断传感器 1、6、8、9 和 10 残差均为正的原因是受到了传感器 3 明显漂移数据的影响。为了解决此问题, 利用图 10(a) 的传感器 3 的预测数据替代实测数据输入网络模型得到预测输出, 传感器 3 预测数据替代漂移数据后其他测点预测结果见图 14), 对比图 14 可以看出图 12 中的异常恢复, 消除了由明显数据漂移现象造成预测不准确的影响。因此, 对于存在明显漂移数据的情况, 可利用预测数据替代测量数据来消除明显漂移数据造成预测偏差。






图 11 传感器 3 数据对其他测点数据的预测权重



(a) 传感器 1



(b) 传感器 6

图 12 传感器 3 漂移数据输入网络模型后其他测点的预测结果






图 13 异常节点为中心节点的有向图



(a) 传感器 1



(b) 传感器 6

图 14 传感器 3 预测数据替代漂移数据后其他测点预测结果

5 结论

针对高铁轨道健康监测系统在服役过程中可能出现结构局部损伤或者发生传感器故障的问题, 本文提出一种基于并行图卷积神经网络的高铁无砟轨道监测测点异常识别方法。该方法的图卷积层采用多个可学习的邻接矩阵学习各传感器测点间的空间关系, 并通过实测值和预测值的对比实现测点数据是否异常的诊断, 其中测点数据异常一般由传感器异常或局部结构异常所致。此外, 本文对漂移数据影响预测输出的问题也提出了解决方案, 对于存在漂移数据的传感器测点, 根据加权邻接矩阵建立有向图进行分析, 利用预测值替代漂移数据消除其对其他测点的预测影响。

为了验证方法有效性, 将本文方法应用于某高铁无砟轨道监测工点的长期应变监测数据的异常识别。建立含 12 个图卷积层的并行图卷积神经网络模型, 利用早期高铁轨道初始状态监测数据训练该模型。模型利用空间上具有相关性的周围测点对中心测点进行预测, 通过对比测量值与预测值, 实现对测点监测数据的诊断。此外, 本文也研究了有向图在消除数据漂移问题中的应用, 在确定漂移数据测点后, 利用预测数据替代漂移数据可

消除了漂移数据对预测结果的影响。

参考文献

- [1] NBA, YU M B, KO C. Organizational and Institutional Factors Affecting High-speed Rail Safety in Japan [J]. Safety Science, 2020, 128: 104762.
- [2] LIU D R, LU Z J, CAO T P, et al. A Real-time Posture Monitoring Method for Rail Vehicle Bodies Based on Machine Vision [J]. Vehicle System Dynamics, 2017, 55(6): 853-874.
- [3] 肖菊, 段鹏飞. 面向楼宇结构健康的光纤传感网络监测系统研究 [J]. 红外与激光工程, 2021, 50(8): 281-287.
- XIAO J, DUAN P F. Research on Optical Fiber Sensor Network Monitoring System for Building Structural Health [J]. Infrared and Laser Engineering, 2021, 50(8): 281-287.
- [4] LI H, OU J P, ZHANG X G, et al. Research and Practice of Health Monitoring for Long-span Bridges in the Mainland of China [J]. Smart Structures and Systems, 2015, 15(3): 555-576.
- [5] 欧进萍, 侯爽, 周智, 等. 多段分布式光纤裂缝监测系统及其应用 [J]. 压电与声光, 2007, 29(2): 144-147.
- OU Jinping, HOU Shuang, ZHOU Zhi, et al. The Multi-Line Distributed Fiber Optic Crack Detection System and Its Application [J]. Piezoelectrics & Acoustooptics, 2007, 29(2): 144-147.
- [6] 朱宏平, 翁顺, 王丹生, 等. 大型复杂结构健康精准体检方法 [J]. 建筑结构学报, 2019, 40(2): 215-226.
- ZHU Hongping, WENG Shun, WANG Dansheng, et al. Precise Structural Health Diagnosis of Large-Scale Complex Structures [J]. Journal of Building Structures, 2019, 40(2): 215-226.
- [7] 李宏男, 田亮, 伊廷华, 等. 大跨斜拱桥结构健康监测系统的设计与开发 [J]. 振动工程学报, 2015(4): 574-584.
- LI Hongnan, TIAN Liang, YI Tinghua, et al. Design and Development of Structural Health Monitoring System for Long-Span Oblique Arch Bridge [J]. Journal of Vibration Engineering, 2015(4): 574-584.
- [8] 罗尧治, 赵靖宇, 范重, 等. 雄安站屋盖钢结构无线健康监测系统设计与开发 [J]. 建筑结构, 2021, 51(24): 21-25, 12.
- LUO Yaozhi, ZHAO Jingyu, FAN (Chong/Zhong), et al. Design and Development of Wireless Health Monitoring System for Roof Steel Structure of Xiong'an Station [J]. Building Structure, 2021, 51(24): 21-25, 12.
- [9] 周洋, 孙强. 基于监测树的高速铁路光传送网络故障定位研究 [J]. 铁道学报, 2020, 42(4): 82-89.
- ZHOU Yang, SUN Qiang. Research on Fault Location of High-Speed Railway Optical Transmission Network Based on Monitoring Tree [J]. Journal of the China Railway Society, 2020, 42(4): 82-89.
- [10] 冷伍明, 周思危, 聂如松, 等. 既有重载铁路路桥过渡段轨道结构纵向差异沉降监测分析与预测 [J]. 铁道学报, 2021, 43(6): 150-157.
- LENG Wuming, ZHOU Siwei, NIE Rusong, et al. Monitoring Analysis and Prediction of Longitudinal Differential Settlement of Track Structures in Bridge-subgrade Transition Sections in Existing Heavy-haul Railways [J]. Journal of the China Railway Society, 2021, 43(6): 150-157.
- [11] 杜彦良, 苏木标, 刘玉红, 等. 武汉长江大桥长期健康监测和安全评估系统研究 [J]. 铁道学报, 2015, 37(4): 101-110.
- DU Yanliang, SU Mubiao, LIU Yuhong, et al. Study on the Long-Term Health Monitoring and Safety Evaluation System for the Wuhan Yangtze River Bridge [J]. Journal of the China Railway Society, 2015, 37(4): 101-110.
- [12] 林超. 持续高温对 CRTS II 型板式无砟轨道温度场影响的试验研究 [J]. 铁道建筑, 2016, 56(5): 15-18.
- LIN Chao. Experimental Study on Influence of Sustained High Temperature on Temperature Field of CRTS II Slab-Type Ballastless Track [J]. Railway Engineering, 2016, 56(5): 15-18.
- [13] 王增光, 王海起, 陈海波. 基于图卷积网络的短时交通速度预测 [J]. 计算机与现代化, 2021(9): 99-105.
- WANG Zengguang, WANG Haiqi, CHEN Haibo. Short-Term Traffic Speed Prediction Based on Graph Convolutional Network [J]. Computer and Modernization, 2021(9): 99-105.
- [14] 曾筠程, 邵敏华, 孙立军, 等. 基于有向图卷积神经网络的交通预测与拥堵管控 [J]. 中国公路学报, 2021, 34(12): 239-248.
- ZENG Yuncheng, SHAO Minhua, SUN Lijun, et al. Traffic Prediction and Congestion Control Based on Directed Graph Convolution Neural Network [J]. China Journal of Highway and Transport, 2021, 34(12): 239-248.
- [15] 杨光泽, 欧阳勇, 孙思思, 等. 基于图卷积网络嵌入社交关系的毕业去向预测 [J]. 计算机应用研究, 2021, 38(11): 3322-3326, 3365.
- YANG Guangze, OUYANG Yong, SUN Sisi, et al. Prediction of Graduation Destination Based on Graph Convolutional Network Embedded Social Relations [J]. Application Research of Computers, 2021, 38(11): 3322-3326, 3365.
- [16] 张刘超, 荣志炜, 赵薇薇, 等. 图卷积神经网络在组学数据分类预测中的应用 [J]. 中国卫生统计, 2021, 38(4): 533-535.
- ZHANG Liuchao, RONG Zhiwei, ZHAO Weiwei, et al. Application of Graph Convolution Neural Network in Classification and Prediction of Omics Data [J]. Chinese Journal of Health Statistics, 2021, 38(4): 533-535.
- [17] GUO K, HU Y L, QIAN Z, et al. Optimized Graph Convolution Recurrent Neural Network for Traffic Prediction [J]. IEEE Transactions on Intelligent Transportation Systems, 2021, 22(2): 1138-1149.
- [18] GENG X, LI Y G, WANG L Y, et al. Spatiotemporal Multi-Graph Convolution Network for Ride-Hailing Demand Forecasting [J]. Proceedings of the AAAI Conference on Artificial Intelligence, 2019, 33(1): 3656-3663.
- [19] LI S L, NIU J, LI Z L. Novelty Detection of Cable-Stayed Bridges Based on Cable Force Correlation Exploration Using Spatiotemporal Graph Convolutional Networks [J]. Structural Health Monitoring, 2021, 20(4): 2216-2228.
- [20] WU Z, PAN S, LONG G, et al. Graph WaveNet for Deep Spatial-Temporal Graph Modeling" [EB/OL]. 2019: arXiv: 1906.00121. <https://arxiv.org/abs/1906.00121>