



河北经贸大学

Hebei University of Economics and Business

硕士学位论文 (学术学位)

烧结配矿优化模型及烧结矿 质量预测研究

学位申请人：武晓婧

指导教师：孙立辉教授

学科专业：计算机应用技术

学位类别：工学硕士

培养学院：信息技术学院

答辩日期：二〇二〇年五月

中图分类号： TP39

密级： 公开

UDC： 004

学校代码： 11832

烧结配矿优化模型及烧结矿 质量预测研究

The Research on Sintering Ore Optimization
Model and Sinter Quality Prediction

学位申请人： 武晓婧

指导教师： 孙立辉教授

学科专业： 计算机应用技术

学位类别： 工学硕士

培养学院： 信息技术学院

答辩日期： 二〇二〇年五月

学位论文原创性声明

本人所提交的学位论文《烧结配矿优化模型及烧结矿质量预测研究》，是在导师的指导下，独立进行研究工作所取得的原创性成果。除文中已经注明引用的内容外，本论文不包含任何其他个人或集体已经发表或撰写过的研究成果。对本文的研究做出重要贡献的个人和集体，均已在文中标明。

本声明的法律后果由本人承担。

论文作者（签名）：武晓娟

2020年5月20日

指导教师确认（签名）：孙立涛

2020年5月20日

学位论文版权使用授权书

本学位论文作者完全了解河北经贸大学有权保留并向国家有关部门或机构送交学位论文的复印件和磁盘，允许论文被查阅和借阅。本人授权河北经贸大学可以将学位论文的全部或部分内容编入有关数据库进行检索，可以采用影印、缩印或其它复制手段保存、汇编学位论文。

（保密的学位论文在年解密后适用本授权书）

论文作者（签名）：武晓娟

2020年5月20日

指导教师（签名）：孙立涛

2020年5月20日

摘 要

烧结是钢铁冶炼过程中的重要环节,烧结矿质量的好坏直接影响高炉炼铁等后续生产。影响烧结矿质量的因素主要有两类,一是原材料配比,二是烧结工艺。由于烧结工艺是一个复杂的理化过程,且控制参数较多,很难做到精确建模和控制。目前烧结炉一般工艺参数固定,工人凭经验设定原材料配矿方案进行生产。该方法烧结矿质量严重依赖于工长经验,产品质量不稳定、成本不容易控制。本文通过对合作企业河北普阳钢厂多年积累的配矿方案及烧结矿理化分析结果进行数据分析,完成三方面工作:一是成本最优烧结配矿算法设计,二是考虑环保和成本指标的多目标配矿优化算法设计,三是建立以配矿方案为输入,烧结矿理化指标为输出的烧结矿质量预测模型,通过模型可以预测给定方案的烧结结果,以辅助企业优化配矿方案,从而稳定产品质量、降低生产成本。前两项工作主要解决在烧结矿质量指标、环保指标约束下获取最优配矿方案问题,第三项工作解决对给定配矿方案预测烧结矿理化指标,在一定程度上替代烧结杯实验。本文具体研究工作如下:

(1) 提出了一种基于粒子间隔 D-PSO 烧结配矿算法,建立了以成本最优为目标的配矿模型。在标准 PSO 算法的粒子速度更新基础上,将粒子与当前最优解的距离融入到粒子速度更新中,使粒子具有依据距离自主判断的能力,从而较为有效的解决标准 PSO 易陷入局部最优的问题。以烧结生产过程中配矿方案及对应的理化分析结果数据对算法效果进行验证,与人工配比方案、和文献中采用的标准 PSO 算法、遗传算法、蚁群算法计算所得方案进行了对比分析,实验结果表明,D-PSO 算法在符合烧结配矿生产要求的前提下,降低了企业的生产成本,同时提高了烧结矿中铁含量。

(2) 提出了一种基于 MOEA/D 的多目标粒子群烧结配矿优化算法(MOEA/D-DPSO),建立了以硫含量和成本指标最低的多目标配矿模型。该算法将提升了全局收敛能力的 D-PSO 算法与 MOEA/D 结合,并引入反向学习策略,平衡了收敛性和分布性,从而平衡了算法在进化过程中的全局收敛能力和局部搜索能力。在符合烧结配矿生产要求的前提下,实验结果表明,该算法相比于人工配矿方案有效降低了硫含量和成本。此外,相比于 MOEA/D 与多策略机制改进的 MOEA/D 算法、ANSGA-II 算法,MOEA/D-DPSO 有效提升了算法全局收敛能力,较为有效的防止其陷入局部最优。

(3) 构建了一种基于注意力机制-LSTM 的烧结矿质量预测模型。在 LSTM 网络的基础上，利用注意力机制思想，通过权重的再分配，关注更多的缺失数据之外的数据，而抑制数据中对训练无更大贡献的冗余数据。提出了加权均方误差损失计算方式，将每轮输入数据中缺失值占总体的比重考虑进去，减少损失函数在训练过程中的震荡，使模型预测更为准确。实验结果表明，增加注意力机制的 LSTM 预测方法的预测准确率可达 92.7%以上，相比于原始 LSTM，预测准确率提升了 1.9%。

关键词：烧结配矿；质量预测；群体优化算法；长短期记忆网络；注意力机制

Abstract

Sintering is a complex physical and chemical process. It is the primary link in the steel production process. The quality of sinter directly affects other subsequent production such as blast furnace ironmaking. Sintering ore and sinter quality prediction are two important components in controlling the quality of sinter in sintering. At present, in both aspects, it is still in the stage of relying on experience value and adjusting process parameters, but it has problems such as wasting resources, high production cost and low production efficiency. Through the historical production data accumulated by steel companies for many years, from the perspective of industrial data, the establishment of the model is relatively simple and easy to achieve, and can achieve the purpose of meeting production requirements, reducing production costs, and improving production quality. Therefore, this paper will study the sintering ore optimization method and the sinter quality prediction method through the industrial data in the sintering production process accumulated by the iron and steel enterprises for many years. The main research work is as follows:

(1) A particle-distribution D-PSO-based sintering ore blending algorithm is proposed, and a blending model with cost optimization is established. Based on the particle velocity update of the standard PSO algorithm, the distance between the particle and the current optimal solution is integrated into the particle velocity update, so that the particle has the ability to judge independently according to the distance, thus solving the problem that the standard PSO is easy to fall into the local optimum. The actual production data of sintering ore blending is used as the experimental data, and the artificial proportioning scheme is compared with the D-PSO algorithm, the standard PSO algorithm, the genetic algorithm and the ant colony algorithm. The experimental results show that the D-PSO algorithm is Under the premise of meeting the requirements of sintering ore production, the production cost of the enterprise is reduced, and the iron content in the sinter is increased, and the content of harmful components such as sulfur and phosphorus is lowered.

(2) A multi-objective particle swarm sintering blending optimization algorithm based on MOEA /D (MOEA/D-DPSO) is proposed, and a multi-target blending model with the lowest

sulfur content and cost index is established. This algorithm combines the D-PSO algorithm with improved global convergence ability with MOEA / D, and introduces a reverse learning strategy to balance the convergence and distribution, thereby balancing the global convergence ability and local search ability of the algorithm during the evolution process. Experimental results show that compared with the artificial ore blending scheme, the algorithm can effectively reduce the sulfur content and cost on the premise that it meets the sintering blending production requirements. In addition, compared with the improved MOEA/D and multi-strategy mechanisms of MOEA/D algorithm, MOEA/D-DPSO effectively improves the algorithm's global convergence ability and prevents it from falling into a local optimum.

(3) A sinter quality prediction algorithm based on attention mechanism-LSTM is proposed to establish a sinter quality prediction model. On the basis of the LSTM network, using the attention mechanism idea, through the redistribution of weights, paying more attention to data other than missing data, and suppressing redundant data in the data that does not contribute more to training. From another level, the consideration of missing data is strengthened, and the calculation of the loss function in LSTM is improved. The proportion of missing values in the total input data is taken into account, and the loss function is reduced during the training process. Make model predictions more accurate. The experimental results show that the prediction accuracy of the LSTM prediction method with increased attention mechanism can reach more than 92.7%, which is 1.9% higher than the original LSTM.

Keywords: Sintering ore; Quality prediction; Group optimization algorithm; Long-Short Term Memory; Attention Mechanism

目 录

1 绪论.....	1
1.1 研究背景与意义.....	1
1.2 国内外研究现状.....	1
1.2.1 成本最优烧结配矿算法研究现状.....	2
1.2.2 多目标配矿优化算法研究现状.....	4
1.2.3 烧结矿质量预测方法的研究现状.....	6
1.3 论文的主要工作.....	7
2 烧结工艺基础.....	10
2.1 引言.....	10
2.2 烧结矿指标要求.....	10
2.3 烧结矿质量检测方法.....	11
2.4 本章小结.....	12
3 基于粒子间隔 PSO (D-PSO) 烧结配矿优化方法.....	13
3.1 问题分析.....	13
3.2 目标函数及约束条件.....	13
3.3 基于粒子间隔的 PSO 算法烧结配矿模型建立.....	15
3.3.1 标准 PSO 算法.....	15
3.3.2 基于粒子间隔的 PSO 算法.....	16
3.4 实验结果与对比分析.....	19
3.5 本章小结.....	23
4 MOEA/D-DPSO 烧结配矿优化算法.....	24
4.1 问题分析.....	24
4.1.1 多目标优化.....	24
4.1.2 烧结配矿多目标优化目标函数与约束条件.....	25
4.1.3 MOEA/D 多目标进化算法.....	26
4.2 MOEA/D-DPSO 的烧结配矿模型建立.....	27
4.2.1 基于种群状态的判断机制.....	28

4.2.2 基于反向学习的进化策略.....	29
4.3 实验对比与分析.....	30
4.4 本章小结.....	31
5 基于注意力机制—LSTM 算法实现烧结矿质量预测.....	32
5.1 LSTM 与 Attention 的工作原理.....	33
5.1.1 LSTM 工作原理.....	33
5.1.2 注意力机制的工作原理.....	34
5.2 基于注意力机制的 LSTM 烧结矿质量预测模型.....	35
5.2.1 烧结矿质量预测模型的建立.....	35
5.2.2 加权均方误差损失.....	36
5.3 实验结果对比与分析.....	38
5.3.1 实验数据与评价指标.....	38
5.3.2 实验结果与分析.....	39
5.4 本章小结.....	42
6 总结与展望.....	43
6.1 总结.....	43
6.2 展望.....	44
参考文献.....	45
作者简介.....	49
致 谢.....	50

1 绪论

1.1 研究背景与意义

钢铁行业所带来的经济效益在国民生产总值中占有较高的比例,是衡量一个国家综合实力和经济水平的重要指标,对相关行业以及国民经济的整体发展起着关键作用。随着钢铁用量的不断增加,使得优质铁矿粉不断减少,国内钢铁企业大多依靠国外进口铁矿石,来源不稳定,从而导致烧结厂的原料种类多且杂,这直接影响烧结矿的质量^[1]。烧结矿质量的高低直接影响着高炉炉况和钢铁产品的质量,烧结矿中全铁波动增加 0.1 %,将引起高炉减产 0.33%-0.40%;烧结矿碱度波动增加 0.01,高炉减产 0.20%-0.40%。

目前,在烧结生产过程中,寻找合理配矿方案的方法主要有两种:第一种方法是根据工长的生产经验配矿,生产过程中根据配料和烧结流程中采集到的烧结矿理化指标,对方案进行修改和微调^[2]。这种凭经验确定生产方案的缺点就是:对于各个生产工艺的规律难以掌握,对生产参数准确度的把握难以控制在合理范围内,从控制的角度看,烧结过程属于大滞后系统,反馈调整周期较长,容易造成烧结矿质量不稳定,另外人工调节也不易控制生产成本。第二种方法是对给定配矿后先进行烧结杯实验试烧合格后将方案再用于生产。这种方法试验周期长、需要额外的设备投入。

本项目的合作企业河北普阳钢厂信息化程度先进,多年来积累了大量的生产数据。本文利用多年来累积的烧结配矿方案及其对应的烧结矿理化分析数据,采用数据分析的方法研究烧结配矿优化及烧结矿质量预测,为企业寻找优化的配矿方案、建立烧结质量预测模型,促进企业降低生产成本,稳定产品质量,减少钢铁企业在生产过程对环境造成的污染。

1.2 国内外研究现状

本小节分别对烧结配矿优化方法与烧结矿质量预测方法进行调研,对调研结果,进行了比较及归类分析。

1.2.1 成本最优烧结配矿算法研究现状

一般来说, 烧结配料问题模型建立的目的是在保证烧结矿性能、冶金性能等符合实际生产工艺要求的前提下, 尽可能降低配料成本, 减少环境污染^[3]。虽然各个优化算法的数学模型建立过程类似, 但还是有各自的特点和计算条件。本章节从单目标优化方面, 介绍优化算法各自的特点和目前的研究情况。

在烧结配矿中, 最关注的是配矿方案的成本问题, 因此在单目标优化烧结配矿方案中大多是以成本最低为优化目标^[4]。线性规划方法是最早应用于烧结配料的优化算法, 烧结配料实际上可以转化为线性规划问题。其最基本的做法就是首先根据要解决的问题, 建立相应线性数学模型, 对此模型进行求解, 进而得到烧结配料的优化解。国内最早应用线性规划法解决烧结配料优化问题是在 20 世纪 80 年代, 单纯形法是当时求解线性规划问题的最常用方法^[8]。其基本思想是从某个基本可行解转换到另一个基本可行解的迭代过程, 直到找到最优基本可行解为止。在单纯形法的基础上, 周景生^[9]运用线性规划法求解最佳配料比, 与实际生产相比每吨降低了 3.95 元, 烧结工艺指标也得到了改善。随着烧结配料约束条件的不断增多, 烧结配料问题更趋于非线性。王伟、陈畏林^[6]等人在此基础上又引入了松弛变量, 并将其投入实际生产中, 与实际生产相比, 每吨烧结矿可节约 5.71 元。线性规划也已发展了几十年, 技术相对成熟, 在烧结配料方面应用研究还有不少^{[10][11][12][13][14][15]}。由此可见, 线性规划法在单目标烧结配矿优化应用较为广泛, 对烧结配矿优化模型的建立有着重要的意义。

遗传算法最早是由美国的 Holland 教授提出, 借鉴了孟德尔的遗传学说和达尔文“适者生存”的进化学说^[16]。在搜索过程中自动获取搜索空间的内容, 并自适应地控制搜索方向, 从而得到最优解。遗传算法中的惩罚函数可以灵活地处理各种约束条件, 通过调整惩罚函数的权重大小控制各个约束条件的优先级别, 使烧结配料优化模型求解过程更加符合钢铁实际生产要求。在烧结配料方面, 随着变量与约束条件的不断增多和模型复杂度的增大, 在烧结配料中得到了大范围的使用。侯武民等人将遗传算法运用到烧结配料中, 在满足实际生产要求的前提下, 优化配料使得每吨原料成本降低了 6.471 元, 同时 TFe 的含量增加了 0.2^[17]。李智、姚驻斌等结合免疫算法与遗传算法, 将其运用到配料的过程中, 通过仿真试验表明满足实际生产要求, 降低成本约 10.32%, 同时提高了各种烧结块的综合利用^[18]。另外, 文献^[19]也对遗传算法在烧结配矿中的应用进行了探

索。

粒子群算法是来源于鸟类群体活动的规律性，模拟鸟群的觅食行为，将寻找最优解的过程看成鸟群觅食的过程^{[20][21][22]}。与其他进化算法类似，粒子群算法通过个体之间的协作与竞争，完成复杂问题的最优化搜索。但粒子群算法与其他进化算法又不太一样，由于每个粒子在解形成的空间内部运动速度都是一定的，并不断地向每个粒子的最优解和整体粒子群体的最优解聚集。粒子的运动聚集方式，很大程度上决定了最终解的优化性能。针对粒子更新方面，众多学者做出了研究。吴敏等在标准粒子群算法中引入共轭梯度法，当群体信息陷入停滞时将目标函数进行适当调整，优化结果与标准粒子群算法相比，有害元素得到更有效的限制，TFe 含量也得到了提升，同时每吨成本降低了 8.2 元，以年用量 100 万吨计算，每年可节约 821 万元，从而为企业节约了大量资金^[23]。李智等以武汉钢铁集团公司烧结厂的烧结配料为例，将粒子群算法与普通数学方法进行比较，计算结果表明粒子群算法比数学方法具有更好的寻优能力和更高的计算精度，实验结果表明粒子群算法使得每吨成本降低了 7.9 元^[24]。

蚁群算法，顾名思义，是一种模拟大自然中蚁群找寻食物路径方法的算法，该算法由 M. Dorigo 等人于 1996 年提出，其主要思想是使用启发式搜索的方法在种群中搜索最优解^[25]。蚂蚁在运动过程中，能够在它所经过的路径上留下信息素^[26]进行信息传递，由于蚂蚁种群巨大，当其共同运动时，就会对所表征的信息起到正向增强的作用，即信息正反馈：当希望相应蚂蚁改选某条路线的概率更大时，蚁群算法的结果就是使得这条路径上的蚂蚁更多^[26]。徐伟等根据杭钢炼铁厂的实际工艺要求，将原料的烧结、烧结指标和最终混合后矿产的目标成分进行分析选择，还使用了蚁群算法得到配料规划与将要生成的成分，现场应用表明蚁群算法是解决烧结配料复杂性问题的有效途径^[27]。刘红芳等将二氧化硅和 TFe 形成的混合均匀矿含量做为将要优化的目标函数，建立了二氧化硅与 TFe 结合的烧结主原料混匀矿配料数学模型，采用蚁群算法对混匀矿配比进行实时优化计算，使得每个时刻的矿料中二氧化硅与 TFe 含量都与总矿料堆的预测成分含量大致相同^[28]。

由于每一种优化算法的设计思想都各自不同，从而导致了优化算法都具有各自的优缺点。表 1-1 对各个优化算法的优缺点和计算条件进行了总结。

表 1-1 优化算法对比分析表

优化算法	优点	缺点	计算条件
线性规划	简单易于操作	对复杂性问题可能无法得到解	规模小；关系简单
遗传算法	是并行自适应的概率搜索技术；对问题本身的依赖性较小。	遗传算法存在局部搜索能力较差和“早熟”现象。	关系复杂；多目标优化问题
粒子群算法	算法思想简单易于理解，收敛速度较快	容易陷入停滞状态	优化问题；
蚁群算法	是一种具有并行、自组织，正向信息反馈的算法；参数设置少。	参数的选取、设定比较复杂	TSP 问题；组合优化求解；

1.2.2 多目标配矿优化算法研究现状

除成本优化外，控制烧结过程中有害物质排放量，也是企业生产追求的一个重要目标。多目标配矿优化算法同时考虑环保和成本等多种指标，属于多目标优化问题。目前相关文献报道的方法主要有遗传算法、差分进化算法、线性规划、神经网络、粒子群算法、MOEA/D 等。

文献^[29]将结构理论和有限时间热力学引入到转炉炼钢程序的通用结构优化中。使用钢水屈服 (MSY) 和有用能量 (UE) 的复杂函数作为优化目标。原材料总成本 (TRMC) 是固定的。获得了最佳的原材料成本分配。分析了铁水成分，铁水温度，钢渣碱度以及废钢与烧结矿价格比对最佳性能的影响。优化后，复杂功能，MSY 和 UE 分别提高了 2.67%，2.21% 和 3.12%。CSMP 的性能得到了一定程度的提高。减少硅，磷、锰和废钢的含量与烧结矿的价格比以及适当提高钢渣的碱度会增加其复杂的功能。此外，通过优化铁水温度，压力比和相对压降，MCF 达到其最大值的两倍。文献^[30]提出了基于 BP 神经网络的烧结过程多目标优化分析模型。结合遗传算法简化了 BP 神经网络，减少学习时间，提高网络模型的预测精度。烧结过程中进行实验。同时考虑生产成本，能耗，质量（旋转强度）和产量。分析了一些因素与多目标之间的关系，达到了不错的优化效果。文献^[31]并提出了一种基于定性和定量综合模型的 Pb-Zn 烧结共混过程的多目标智能协调优化策略，以得到最优的配合比。文献^[32]提出了基于线性规划 (LP) 和非线性规划 (NLP) 方法结合的烧结矿匹配高炉工艺的炼铁系统优化模型，以能耗，二氧化碳排放量和成本最小化为优化目标。根据建模中的实际生产经验，考虑了一些关键约束。给出了给定条件下的最佳烧结矿匹配方案 and 不同目标的优化结果。文献^[33]提出了一种基于

模糊满意度的多目标优化算法。首先，建立了可以描述成本和含硫量实际满意程度的模糊满意函数，然后建立了一个多目标优化模型，在该模型中，考虑了成本和排放量以使最小满意程度最大化。其次，针对该模型的非线性和多变量特征，结合粒子群优化(PSO)算法的强大映射能力和强大的蜂群(BC)算法的局部搜索能力。文献^[34]提出了量质指标参数，工艺参数和运行参数的关系模型，综合了许多技术，包括主成分分析，神经网络，灰色关联分析等。并推导了整个烧结过程中协调优化控制的目标功能。其次，采用多目标协同进化算法计算优化参数。最后，设计了模糊专家协调控制器来协调整个烧结过程，并介绍了优化指导。文献^[35]通过使用主成分分析(PCA)和与理想解决方案(TOPSIS)相似的顺序偏好技术的混合方法，完成了多目标优化，从而获得了铜和Cu-Cr-Ni工具的最佳参数集。文献^[36]提出了一种基于混沌搜索的多目标粒子群算法，计算出优化参数；并介绍了优化指南。实际运行结果表明，所提出的智能集成算法为解决复杂的强相关耦合，时变时滞工业过程的优化控制问题提供了一种有效的方法，为实现全局优化提供了有效的新思路。文献^[37]提出了一种基于层次分析法(AHP)和线性规划(LP)的优化方法，以达到最短行走路径和最大利用堆取料机的目的。首先，将每个目标的权重使用基于层次的分析方法确定，这种方式使得多目标优化成功转换为单目标优化。其次，采用LP法求解优化模型。文献^[38]提出了一种基于分解的多目标进化算法(MOEA/D)。它将多目标优化问题分解为多个标量优化子问题，并同时对其进行优化。仅通过使用来自其几个相邻子问题的信息来优化每个子问题，这使得MOEA/D在每一代的计算复杂度均低于MOGLS和非主导排序遗传算法II(NSGA-II)。文献^[39]提出了一种快速非支配排序遗传算法(newNSGA-II)，该方法使用快速非支配策略对遗传算法进行改进，使其进行极值过滤，减少了噪声数据对算法的影响，达到了不错的效果。但该算法时间复杂度较高，运行效率较低。

通过调研分析，PSO、MOEA/D、遗传算法、差分进化算法在烧结矿多目标优化领域应用效果较好，但这些算法均有相应的缺陷。如将MOEA/D与差分进化结合的改进MOEA/D算法，单纯的使用差分进化算法导致其局部搜索能力降低，使用遗传算法为基础算法的NSGA-II算法时间复杂度较高，而NSGA-II时间复杂度较高的根本原因在于遗传算法内部寻优过程复杂，使其很难进行较大的时间性能提升。故本文将使用优化能力较好的MOEA/D算法作为基础算法。

1.2.3 烧结矿质量预测方法的研究现状

目前,在烧结矿质量预测方法主要包括 BP 神经网络、灰色理论、专家系统、Elman 神经网络等。烧结矿质量的稳定性是烧结过程中重要环节,烧结矿质量的好坏直接影响着高炉炼铁的稳定性的。

韩庆虹等人通过建立烧结矿质量指标预测的神经网络模型,利用实际烧结生产数据对模型进行训练,对烧结矿低温还原粉化性能(RDI)和转鼓强度(TI)进行预测,命中率可达 90%以上^[40]。张军红等人使用遗传算法优化 BP 中的参数初始化机制,建立了混合结合算法的烧结矿质量预测模型,并改进 BP 网络学习算法^[41]。预测烧结矿 FeO 含量和烧结矿碱度 R 指标仿真结果表明,模型能取得良好的预测结果。刘颂以 BP 神经网络为核心建立了烧结基础特性预报模型、烧结矿质量预报模型以及寻优配矿模型。通过化学成分预报烧结基础特性和烧结矿质量,模型各项指标的预报命中率均高于 83%^[42]。从理论上讲,最基本的三层 BP 神经网络能对任意非线性问题进行拟合,但在实际应用中发现 BP 神经网络仍存在很多不足:收敛速度慢、隐藏层节点难以为确定等。李宗平,范晓慧等人建立一个新的人工神经网络模型-在线顺序极限学习机(OS-ELM)来预测每组烧结矿中的 FeO 含量和滚动强度^[43]。验证结果表明,所建立的 OS-ELM 模型比常规 BP(反向传播)模型具有更高的准确性。

宋强提出通过灰色神经网络对烧结矿质量进行预测,但此模型仅在小样本的条件下对烧结矿碱度准确预测^[44]。牛江峰、周静等人针对铁矿石烧结过程工艺流程长、影响因素多、机理复杂的特点,根据灰色理论模型的原理确定出参考序列和比较序列,利用灰色关联分析方法评价参考序列与比较序列的合理性,从而指导实际生产操作^[45]。其问题在于只适用于小样本。目前,工业生产数据已不再是小样本数据,通过灰色理论很难挖掘到工业生产数据中的潜在价值与意义。

由于烧结过程的大滞后性、非线性和强耦合性,Elman 神经网络逐渐应用于烧结矿质量预测中。汪清瑶,刘琼通^[46]过 Elman 神经网络方法预测烧结矿质量,预测结果。但浅层的网络算法未能充分挖掘到烧结过程的本质规律,不能达到实际生产的要求。

随着深度学习的不断发展,深层的网络算法也被应用于烧结矿质量预测中。袁志强通过深度置信网方法,对烧结矿化学成分的预测准确率达到了 87.62%,为烧结矿化学成分的稳定控制提供了新思路^[47]。王斌等人提出一种基于深度置信网的烧结矿质量预测

方法，能够挖掘到烧结过程的本质规律，从而提高烧结矿成分预测的精度^[48]。烧结过程中之前的配料会对之后的过程造成影响，其在时间维度上前后存在一定的时序关系，但深度置信网并没有明确地处理对观察变量的时间联系上的学习。短时记忆网络（LSTM）是解决时序问题的有效方法，目前 LSTM 在各个领域得到了广泛应用：在气象领域中，能够准确预测空气质量^[49]，气候现象^[50]等；在经济领域中，能够挖掘到股票市场变化的内在规律^{[51][52]}等；在能源领域中，融合注意力机制对热电进行预测^[53]。

通过对烧结配矿优化方法与烧结矿质量预测方法文献的总结与分析，可以发现：

（1）在烧结配矿优化方法中，最早解决该问题的是线性规划法^[8]，但随着变量与约束条件的不断增多和模型复杂度的增大，遗传算法、粒子群算法、蚁群算法等智能优化算法也相继应用到烧结配料方面。侯武民等人^[17]将遗传算法运用到烧结配料中；李智、姚驻斌等^[18]结合免疫算法与遗传算法，将其运用到配料的过程中，通过仿真试验表明满足实际生产要求，同时提高了各种烧结块的综合利用。但遗传算法的参数较多，实现步骤较为复杂，且参数的选择对算法的寻优结果有较大的影响。PSO 算法相较于遗传算法、蚁群算法等优化算法简单易操作，更适合于工程人员的操作，但简单的 PSO 算法与上述对 PSO 算法的改进算法，在一定程度上较容易陷入局部最优，且粒子更新方式上也有待进行探究。

（2）在烧结矿质量预测方法中，烧结过程是一个极其复杂的过程，在时间维度上存在一定先后顺序的影响，BP 神经网络算法、DBN 算法、Elman 算法在数据时间关联上并未加以考虑，故其对烧结矿质量的预测性能较差，而从上述分析中可以看出 LSTM 在解决时序问题上有较好的应用背景。

基于以上调研分析，本文在烧结配矿与烧结矿质量预测方面分别以 PSO 算法和长短期记忆网络为基础，展开烧结配矿与烧结矿质量预测方面的研究。

1.3 论文的主要工作

本文针对烧结配矿优化及烧结矿质量预测问题进行研究，主要包括以下三部分内容：

（1）以成本最优为目标的单目标烧结配矿优化算法研究。（2）以硫含量和成本最优为目标的多目标烧结配矿优化算法研究。（3）烧结矿质量预测研究。对给定配矿方

案，能够实现烧结质量的预测。

针对以上研究内容，本文的主要工作如下：

(1) 提出一种基于粒子间隔的 D-PSO 算法，实现对烧结配矿方案的优化。在标准 PSO 算法的基础上，将粒子与当前最优解之间的距离融合进粒子更新中，使粒子在距离上具有自主判断的能力，增加了粒子在寻优过程中的多样性，提高了其在局部搜索的能力。该算法以成本最优为目标，将烧结矿的化学指标作为约束条件，采用 D-PSO 算法寻找最优解。由于在粒子速度更新中加入了粒子间距离的考虑，该算法求解的最优配矿方案较其他同类算法结果更优。在符合生产要求的前提下，该方法计算出的配矿方案与合作企业以往人工依据经验设定的配矿方案相比，成本最少降低 1.32 元/吨，对钢铁企业的效益有显著提高。

(2) 提出了一种基于 MOEA/D 的多目标粒子群烧结配矿优化算法 (MOEA/D-DPSO)，建立了以硫含量和成本指标最低的多目标配矿模型。该算法将全局收敛能力强的 D-PSO 算法与 MOEA/D 结合，并引入反向学习策略，平衡收敛性和分布性，在迭代进化的过程中，使得算法全局收敛能力和局部搜索能力得到均衡。将设计形成的算法进行实验，实验结果表明，该算法相比合作企业人工配矿方案，在符合烧结配矿生产要求的前提下，有效降低了硫含量和成本。此外，相比于 MOEA/D 与多策略机制改进的 MOEA/D 算法，MOEA/D-DPSO 有效提升了算法全局收敛能力，较为有效的防止其陷入局部最优。

(3) 提出一种基于注意力机制—LSTM 的烧结矿质量预测方法，实现对烧结矿质量的预测。由于在真实配料数据中，每轮输入的原料配比数据总会有某种原料未输入的情况，而每轮配料数据的输入均是根据工人多年经验得到，故每轮的缺失数据存在内在的特定联系。因此，在 LSTM 的基础上引入注意力机制的思想，通过训练的方式对各种原料自动分配更为优化的权重，从而降低缺失数据对网络准确性的影响。此外，出于对缺失数据的考虑，提出了加权均方误差损失计算方式。该损失函数将每轮输入数据中缺失值占总体的比重考虑进去，减少损失函数在训练过程中的震荡，使模型预测更为准确。对不同钢种实际生产数据进行了预测实验，实验结果表明，增加注意力机制的 LSTM 预测方法的预测准确率可达 92.7% 以上，相比于原始 LSTM，预测准确率提升了 1.9%。

本文针对以上研究内容进行阐述，共分 6 章，各章的主要内容安排如下：

第一章介绍了关于本文的研究背景与意义、烧结配料优化算法与烧结矿质量预测的

国内外研究现状以及论文的主要研究工作，并在最后列出论文各章节的组织结构。

第二章介绍了涉及到的烧结配矿及烧结矿质量检测的相关知识及生产质量对各项指标的要求。

第三章提出一种基于粒子间隔 D-PSO 算法的烧结配矿优化算法。首先介绍了烧结配矿问题的描述及标准 PSO 算法的基本流程与更新方式，然后结合烧结配矿的实际问题，针对标准 PSO 粒子群算法的缺点，提出了基于粒子间间隔的 D-PSO 算法，该算法将粒子间距离融合到粒子速度更新方式中，使粒子具有依据距离自主判断的能力，从而解决标准 PSO 易陷入局部最优的问题。与标准 PSO 算法及目前应用于烧结配矿中的优化算法进行了对比，验证了算法的有效性。

第四章提出一种基于 MOEA/D 的多目标粒子群烧结配矿优化算法。建立了以硫含量和成本指标最低的多目标配矿模型。该算法将提升了全局收敛能力的 D-PSO 算法与 MOEA/D 结合，并引入反向学习策略，平衡了收敛性和分布性，从而平衡了算法在进化过程中的全局收敛能力和局部搜索能力。实验结果表明，该算法相比于人工配矿方案，在符合烧结配矿生产要求的前提下，有效降低了硫含量和成本。此外，相比于 MOEA/D 与多策略机制改进的 MOEA/D 算法，MOEA/D-DPSO 有效提升了算法全局收敛能力，较为有效的防止其陷入局部最优。

第五章提出一种基于注意力机制-LSTM 的烧结矿质量预测方法。在本章中，首先介绍了烧结矿生产流程的特点与 LSTM 网络的相关基本概念，通过实验结果分析 LSTM 网络在烧结矿质量预测中的问题，从而加入注意力机制，通过分配不同权重，减小缺失数据对网络的影响，提出了加权均方误差损失计算方式。该损失函数将每轮输入数据中缺失值占总体的比重考虑进去，减少损失函数在训练过程中的震荡，使模型预测更为准确。实验结果表明，增加注意力机制的 LSTM 预测方法的预测准确率可达 92.7%以上，相比于原始 LSTM，预测准确率提升了 1.9%。

第六章为总结与展望部分。对论文的内容进行了总结并对未来烧结配矿及烧结矿质量预测的研究进行了展望，提出了未来可进行更深入的研究内容。

2 烧结工艺基础

2.1 引言

目前国内钢厂生产钢材的过程基本都是采用烧结过程实现的,烧结可以大幅度的提升矿石的价值。通过对矿石的烧结生产,可以将自然界中普遍存在的大量可用但又是贫矿的矿石转化为高质量的人工富矿,满足通过工业生产技能使得自然资源得到充分利用的目标。此外,烧结矿生产还可以充分促进钢铁工业发展,对整个钢铁行业的发展有很大的推动作用。在烧结矿整体烧结过程中,可以使得高炉生产中产生的废料,诸如高炉粉,轧钢涂层和使用硫酸后形成的废料等得到充分利用,做到物尽其用,与自然界存在的矿石相比,通过烧结生产的烧结矿石具有适宜的粒度,良好的还原和柔韧性能、稳定的成分,这些有效推动了高炉炼铁的成功进行。在烧结矿过程中,如果加入适当含量的助熔剂或带有溶剂性质的烧结矿,可有效减少熔炉的消耗,从而提高高炉的生产能力。

2.2 烧结矿指标要求

烧结过程可去除大部分的硫、氟等对高炉炼铁无用且污染环境的杂质,使得高炉在脱硫处理的工作量减少了非常多,提高了最终铸铁的质量。为得到化学性能与物理性能较为稳定的烧结矿,在烧结配矿过程中必须保证原料配比符合生产要求,因此在原料配比中必须保证 TFe 、 CaO 、 SiO_2 、 MgO 、 P 、 S 等指标能在符合生产要求的限制之内,这些重要成分的占比非常容易对烧结矿的整体质量造成影响:

(1) TFe 决定了烧结矿中铁的占比,此项指标对钢铁产量有非常明显的影响。

(2) 碱度:当使用 $\frac{CaO}{SiO_2}$ 用于烧结矿质量评估时,其对烧结的钢铁强度,还原性和柔韧性能有非常明显影响。碱性物质含量太高或太低都会使烧结设备形成腐蚀并损坏烧结设备,从而产生大量的非必须生产成本。因此,应将碱性物质含量控制在满足生产要求的合适区间内。

(3) MgO 的含量对炉渣的流动性与稳定性有一定影响,为保证高炉的稳定运行,

应使得 MgO 处于适当范围内，这样可有效烧结矿的烧结制备性能和在低温环境下的矿材还原粉化性能；

（4）二氧化硅、三氧化二铝对于烧结矿的质量检测转鼓指数和燃料消耗方面均有一定影响。合适质量的三氧化二铝可以改善烧结矿混合物的粒化程度，但如果三氧化二铝含量极高，将导致烧结矿中的低温下还原粉化性能变小，以此降低烧结矿的整体性能。二氧化硅和三氧化二铝都是形成铁钙化合物的重要组成成分。当二氧化硅含量极低时，会导致烧结矿渣相较低，使得烧结矿强度降低。当二氧化硅含量极高时，会导致硅酸渣相过高，使得烧结矿的冶炼金属性能降低。

（5）磷、硫的占比若过高，不仅会对环境产生危害，还会对烧结矿质量有很大的影响，因此应将这些成分尽量控制在比较低的水平。

为了保证烧结矿化学成分含量符合生产要求，在原料配比过程中必须严苛的控制化学成分比例在一定范围内，此外，还需要根据原料供应商的供应能力和生产该产品所需的成本对生产中原料的比例进行精细调整。对项目合作钢铁厂家在多年生产中积累的数据进行整理分析，发觉到现有配矿方案中的各种配矿原料和辅料的总种类在 10 种以上，配料成分的不固定，导致了若仅依赖于人工经验，在原料变化的情况下不能快速准确地计算出合理的原料配比。烧结配矿优化算法可以有效判断原料与辅料的化学成分与烧结矿之间的数学函数映射关系，从而实现对烧结矿成分的有效精准计量；能够在较短的时间里计算出符合生产要求且成本较低的配矿方案。表 2-1 中是钢铁企业实际生产中对烧结矿进行的质量指标约束。

表 2-1 烧结矿理化指标要求

TFe (%)	CaO (%)	SiO_2 (%)	CaO/SiO_2 (%)	MgO (%)	P (%)
53.2-54.6	9.62-11.76	5.5-6.0	1.75-1.96	$\geq Al_2O_3$	≤ 0.08

2.3 烧结矿质量检测方法

传统的烧结矿质量检测方式是烧结矿成品出来后，每隔 2 小时对成品矿进行取样检测，通过理化试验对烧结矿的理化指标进行检测（见表 2-1 烧结矿理化指标要求），经过理化试验检测的理化指标如果不满足生产要求，操作员则依靠所掌握的现场生产经验

对相关烧结参数进行人工经验性的“调参”，从而保证后续生产的烧结矿质量。这种反馈调控虽然理论上可以调节烧结矿理化指标，但由于烧结属于大滞后过程，配矿方案的调节一般需 4 个小时左右才能产生效果，因此烧结矿质量的稳定性不高、生产成本也不易控制。

企业特别需要能有一个烧结模型能够在烧结之前对给定配矿方案进行预测，根据预测结果调节配矿方案，从而达到稳定烧结质量的效果。但是烧结是一复杂的物理反应和化学反应过程，其机理及其复杂，很难用数学的方式建模。随着大数据分析技术的不断发展，利用数据驱动的方法构建烧结模型成为可能。本文将利用机器学习理论分析烧结实际生产数据与烧结矿指标之间的对应关系训练模型，得到原料配比与烧结矿指标之间的内在联系，实时快速地预测出烧结矿的理化指标信息。从而大大提高烧结预测的效率、降低生产成本、稳定产品质量。

2.4 本章小结

通过上述关于烧结配矿基本理论及传统烧结矿质量检测的理论介绍，可以看出不论是在烧结配矿方面还是在烧结矿质量检测方面，目前都还是更多依赖与人工经验调整烧结工艺参数，达到提高烧结矿质量的效果。但随着大数据技术的不断发展，钢铁企业对钢铁质量精度要求的不断提高以及传统烧结检测方法的大滞后性，需结合机器学习，智能优化算法从钢铁企业历年来积累的数据中挖掘其潜在的价值，并以此来辅助烧结生产过程中工艺参数的调整与改进。因此，本文在第 3，4，5 章分别就烧结配矿及烧结矿质量检测方面，利用普阳钢铁企业的多年积累的历史烧结生产数据，结合智能优化算法及机器学习等知识展开研究。

3 基于粒子间隔 PSO (D-PSO) 烧结配矿优化方法

3.1 问题分析

烧结是将原料、辅料及熔剂等按照预先定义的矿料配比匀称混合进行烧制，从而生产出烧结矿的过程。由于钢铁需求量的日益增长，优质矿粉的不断减少，从而造成原料种类变化频繁。但在目前的烧结配矿整体流程中，原料配料和烧结方法一般使用基于经验的配料方式，这种配料方式所形成的生产方案严重依赖人工经验，虽然在生产中可以根据生产情况对配料方案进行更新调整^[2]。但这种使用人工经验得到的生产方式配比有较大的缺陷，即：由于钢厂的烧结矿产品多样使得产品的生产工艺不尽相同，导致仅凭人工经验非常不好确定各种烧结矿产品的生产规律，因此相应生产过程中的参数就难以精确控制在较为有效的区间内。此外，在烧结矿生产中会因为产品效果不好需对参数进行长期持续的调整，烧结矿产能较低，要想达到比较好的生产预想状态，需要非常长的参数调节时间，这样的生产流程不仅费时费力还将会造成极大的资源浪费，使得相关厂家的烧结矿生产居高不下，生产效能也难以提升。

3.2 目标函数及约束条件

烧结配料问题模型建立的目的是在保证烧结矿性能、冶金性能等符合实际生产工艺要求的情况下，尽可能降低配料成本。在烧结配料中通常以成本最低为目标函数，以质量指标和污染物排放量对原料的要求为约束条件，进行问题的求解^[2]。根据普阳钢厂的实际生产数据，总结了配矿过程中对各种所需数据的具体计算公式：其中， i 表示参与配料的原料种类， C_i 表示每种参与配料的原料成本， X_i 表示每种原料的用量。

$$P = \min \sum_{i=1}^n C_i X_i (i = 1, 2, \dots, n) \quad (3-1)$$

烧结矿化学成分含量计算公式如下：

$$R = \sum_{i=1}^n X_i \times (1 - H_2O_i) \times (1 - W_i) \quad (3-2)$$

$$M_j = \frac{\sum_{i=1}^n X_i \times (1 - H_2O_i) \times M_{ij}}{R}$$

R 表示烧结原料在经过脱水与烧损后产生的烧结矿占原烧结配料的百分比。 W_i 表示每种原料的烧损， H_2O_i 表示第 i 种原料的含水量， M_j 表示烧结矿第 j 种化学成分在烧结矿中的总含量， M_{ij} 表示第 i 个烧结原料中第 j 中化学成分的含量。

在配料过程中，配料人员需保证烧结配矿中的原料配比之和为 1。同时为确保模型计算结果符合实际生产要求，对每种原料配比根据人工经验都做了上下限的控制，以确保模型计算结果符合实际生产要求。其约束条件如下所示： $X_{i\min}$ 与 $X_{i\max}$ 分别表示第 i 种烧结原料的配比范围。

$$\begin{cases} \sum_{i=1}^n X_i = 1 \\ X_{i\min} \leq X_i \leq X_{i\max} \end{cases} \quad (3-3)$$

在烧结矿中，硫含量与磷含量对钢铁的性能有不利影响，需要对烧结矿中硫含量与磷含量加以限制。公式如下： s_i 与 p_i 分别表示第 i 中烧结原料中的硫含量与磷含量。

$$\sum_{i=1}^n p_i \times X_i \leq 0.08 \quad (3-4)$$

通过上述分析可以得出，烧结配矿优化模型的目标函数与约束条件如(3-5)、(3-6)所示：

$$\min \sum_{i=1}^n C_i X_i \quad (3-5)$$

$$s.t. \begin{cases} X_{i\min} \leq X_i \leq X_{i\max} \\ \sum_{i=1}^n p_i \times X_i \leq 0.08 \\ \sum_{i=1}^n X_i = 1 \end{cases} \quad (3-6)$$

3.3 基于粒子间隔的 PSO 算法烧结配矿模型建立

PSO 算法最早是由 Kennedy 与 Eberhart 共同提出的启发式算法。PSO 算法就是模拟自然界中种群现象的背景而提出，由于其所需调参量参数相对较少，因此该算法实现过程简易可行，同时，在应对非线性、多峰问题等问题时，PSO 的全局搜索能力也是较强的。在电力分配、交通运输、车间调度等领域得到了广泛应用，也证明了 PSO 算法适用于解决模型参数的寻优问题。本文结合实际问题中的约束条件，对标准 PSO 算法进行改进，提出一种根据粒子间距离分类学习的策略，即：通过粒子间的距离值的不同，改变标准 PSO 算法的粒子更新速度，距离当前最优粒子较近的粒子，在其速度更新中通过距离值的调节，增强了算法的局部寻优能力；距离当前最有粒子较远的粒子，在其速度更新中通过距离值的调节，提高了算法的全局搜索能力，降低了陷入局部最优解现象的发生。

3.3.1 标准 PSO 算法

标准 PSO 算法的理论的核心为粒子速度更新与位移更新方式，如公式 (3-7)、(3-8) 所示：式 (3-7) 右边共分为三个分支：第一个分支是粒子固有的速度分支，表示了粒子的活动“趋势”，代表粒子保持自身之前速度的能力；第二个分支为“经验记忆”分支，表示了粒子记忆原来运动位置的能力，在经验记忆的处理下，使粒子朝着自身全局最优解的方向运动；第三个分支是“种群”分支，表示了粒子之间协调共同工作与参数共享的群体记忆原来运动位置的能力，在粒子群体经验记忆的处理下，可以使粒子朝着群体全局最优解的方向运动。

$$v_{ij}^{t+1} = w \times v_{ij}^t + c_1 \times r_1 \times (p_{ij}^t - x_{ij}^t) + c_2 \times r_2 \times (g_{ij}^t - x_{ij}^t) \quad (3-7)$$

$$x_{ij}^{t+1} = x_{ij}^t + v_{ij}^{t+1} \quad (3-8)$$

其存在的问题为，粒子仅依照公式 (3-7)、(3-8) 进行更新，在迭代中后期其降低了粒子的多样性，从而使算法易陷入局部最优解。图 3-1 是根据 3.1 节问题分析所总结出的目标函数与约束条件计算所得。从图中可以看出 PSO 算法在迭代到第 30 次后，陷入了局部最优，针对此问题，本文提出了基于粒子间距离的 PSO(D-PSO)算法。




图 3-1 PSO 算法迭代结果

3.3.2 基于粒子间隔的 PSO 算法

有研究表明，寻优过程中，较优的粒子有更大概率接近最优值。也就是说，距离全局最优值越近的粒子越有可能接近最优值。从图 3-1 中可以看出，PSO 算法与 D-PSO 粒子在迭代初期分布均较为分散，距离当前最优解的粒子相对较少；随着迭代次数的不断增加，从图 3-2 中可以看出，粒子的分布产生了变化，D-PSO 算法中的粒子与当前最优解的距离近的粒子较迭代初期增多，从图中也可看出 D-PSO 算法中的粒子在迭代中期较 PSO 算法能够快速趋于收敛，初期距离最优解较近的粒子在中期较其他粒子来说，能够找到较优的解。但从图 3-3 中可以看出标准的 PSO 算法在后期粒子的变化逐渐减小，寻找更优解的能力减弱；而 D-PSO 算法中的粒子在迭代后期仍保持了粒子的多样性与粒子的寻优能力。在算法初期，种群中的粒子与当前全局最优值距离较大，因此算法初期，较优的粒子较少。随着迭代次数的增加，与当前全局最优值距离小、较优的粒子会逐渐增多。

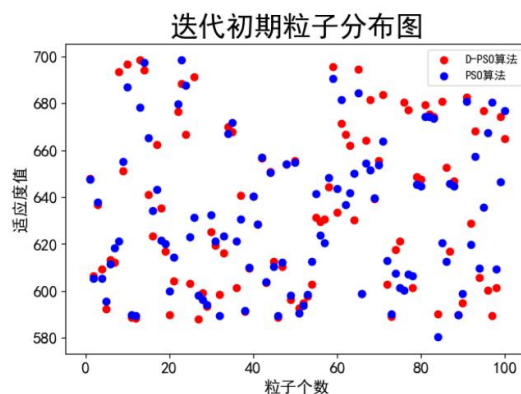


图 3-2 迭代初期粒子分布图




图 3-3 迭代中期粒子分布图




图 3-4 迭代后期粒子分布图

本文根据粒子的适应度与粒子寻优过程中的全局最优值之间的距离，经过计算速度与实验结果的综合考虑，随着粒子分类的数量的增多，其计算时间会随着分类数量的不断增多，计算时间会逐渐增多，将粒子分为三类能够较为快速更好地找到最优解。对每一类粒子按照不同的学习方式更新，在增加了种群多样性的同时，也提高了粒子寻优的速度。

(1) 当前值与全局最优值距离小的粒子。与最优解距离较小粒子，在其邻域内存在较优值的概率大，因此，对其采用局部学习方式，增强局部的搜索能力。将当前值与全局最优值之间的距离设为 d ，将 d ($d \leq 1$) 作为粒子速度更新的参数，如公式(3-9)所示，通过距离 d 减小此类粒子的更新速度，提高其在局部搜索的能力。

$$v_{ij}^{t+1} = d \times w \times v_{ij}^t + c_2 \times r_2 \times (g_{ij}^t - x_{ij}^t) \quad (3-9)$$

(2) 距离全局最优值较远的粒子相对较差，距离 d 相对较大 ($d \geq 5$)，此时需提

高粒子更新速度，如公式(3-10)所示，通过距离 d 加快其向全局最优值靠近的速度，增加与全局最优值距离小的粒子的数量，从而增大其全局寻优的能力。

$$v_{ij}^{t+1} = d \times w \times v_{ij}^t + c_1 \times r_1 \times (p_{ij}^t - x_{ij}^t) \quad (3-10)$$

(3) 处于优劣之间的粒子，其按照标准粒子群算法的学习方式进行更新即可。

$$v_{ij}^{t+1} = w \times v_{ij}^t + c_1 \times r_1 \times (p_{ij}^t - x_{ij}^t) + c_2 \times r_2 \times (g_{ij}^t - x_{ij}^t) \quad (3-11)$$

设粒子与当前全局最优值间的距离为 d ； d_{\min} 与 d_{\max} 为距离的上下界。三类粒子具体的分类更新方法为：

1) 如果 $d \leq d_{\min}$ ，说明粒子为较优粒子，其学习方式如(3-12)式所示：

$$\begin{cases} v_{ij}^{t+1} = d \times w v_{ij}^t + c_2 r_2 [g_{ij}^t - x_{ij}^t] \\ x_{ij}^{t+1} = x_{ij}^t + v_{ij}^{t+1} \end{cases} \quad (3-12)$$

其中， t 代表当前迭代次数， p_{ij}^t 代表当前个体最优

2) 如果 $d_{\min} \leq d \leq d_{\max}$ ，其学习方式如(3-13)所示：其中 p_{ij}^t 代表当前个体最优， g_{ij}^t 代表当前全局最优。

$$\begin{cases} v_{ij}^{t+1} = w v_{ij}^t + c_1 r_1 [p_{ij}^t - x_{ij}^t] + c_2 r_2 [g_{ij}^t - x_{ij}^t] \\ x_{ij}^{t+1} = x_{ij}^t + v_{ij}^{t+1} \end{cases} \quad (3-13)$$

3) 如果 $d > d_{\max}$ ，说明粒子较差，其学习方式如(3-14)式所示：

$$\begin{cases} v_{ij}^{t+1} = d \times w v_{ij}^t + c_1 r_1 [p_{ij}^t - x_{ij}^t] \\ x_{ij}^{t+1} = x_{ij}^t + v_{ij}^{t+1} \end{cases} \quad (3-14)$$

D-PSO 算法的整体流程，如图 3-5 所示。




图 3-5 D-PSO 算法流程图

3.4 实验结果与对比分析

以河北省普阳钢厂 2017 年 3 月 13 日的生产方案作为实验数据。数据主要组成部分如表 3-1 所示。

表 3-1 钢铁企业 2017 年 3 月 13 日实际生产数据

名称	纽曼粉	南非精粉	澳混合粉	西部粉	铁矿砂	罗伊山粉	铁皮	槽返	青石粉
一次料比(%)	18	12	25	15	3	21	1.5	0	0
二次配比	0.00	0.00	0.00	0.00	0.00	0.00	0.00	12	1
单价	582.07	705.27	582.07	582.07	81.37	582.07	400	350	30
成本	0.0	0.0	0.0	0.0	0.0	0.0	0.0	0.0	0.0
单品位价	9.24	11.08	9.98	10.11	1.85	9.57	5.71	0.0	0.0
TFe	62.97	63.67	58.35	57.6	44	60.82	70	53.5	0.0
SiO2	4.22	1.16	5.5	7.02	4.5	5.21	0.5	5.8	5.30
CaO	0.02	1.52	0.059	0.03	0.94	0.05	0	10.5	48.00
MgO	0.06	3.38	0.07	0.05	0.21	0.06	0	2.45	3.24
Al2O3	2.1	0.72	2.5	3.18	15	1.82	0.99	2.5	0.0
P	0.09	0.14	0.065	0.063	0.12	0.057	0.13	0.075	0.0

Cr	0.01	0.0081	0.0098	0.01	0.08	0.0037	0.001	0.05	0.0
s	0.01	0.06	0.034	0.02	0.08	0.048	0.03	0.05	0.0
K	0.06	0.06	0.11	0.08	0.09	0.093	0.039	0.06	0.0
Tio2	0.1	2.16	0.17	0.11	5.43	0.12	0.13	0.45	0.0
Zn	0.01	0.02	0.0087	0.02	0.01	0.0061	0.011	0.0086	0.0
Ni	0.00	0.00	0.00	0.00	0.01	0.00	0.00	0.01	0.0
mn	0.08	0.091	0.75	0.08	0.3	0.086	0.17	0.39	0.0

目前应用在烧结配矿优化中比较广泛且效果较好的算法为标准 PSO 算法、引入松弛变量的 PSO 算法 (APSO)、遗传算法 (GA)、蚁群算法 (ACO) 及新型灾变自适应算法 (New-GA)。本文选取上述 5 种性能较为优良的算法与 D-PSO 算法进行对比。为体现算法对比有效性, 最大可能的降低调参偶然性, 对以上多种算法进行超参数实验对比。对比结果如表 3-2 到 3-6 所示。

表 3-2 本文所提 D-PSO 算法超参数实验对比

序号	学习因子 1(C1)	学习因子 2(C2)	权重 (w)	成本 (元/吨)
1	0.5	0.5	0.9	579.32
2	0.6	0.9	1.0	579.12
3	0.7	1.1	1.2	578.92
4	0.8	1.2	0.8	578.87
5	0.9	1.2	0.8	578.89

上述超参数选取的是经过多次实验得到较优结果的参数, 从参数对比可以看出, 当学习因子 C1、C2 分别为 0.8, 1.2, 权重 w 为 0.8 时, 得到的结果较优。

表 3-3 标准 PSO 算法超参数实验对比

序号	学习因子 1(C1)	学习因子 2(C2)	权重 (w)	成本 (元/吨)
1	0.6	0.8	0.8	584.89
2	0.7	0.9	1.0	584.23
3	0.7	1.0	1.2	583.65
4	0.9	1.1	1.2	584.32
5	0.9	1.2	0.8	585.67

表 3-4 引入松弛变量的 PSO 算法（APSO）超参数实验对比

序号	学习因子 1(C1)	学习因子 2(C2)	权重 (w)	成本 (元/吨)
1	0.5	0.75	0.9	582.32
2	0.6	0.8	1.1	580.35
3	0.75	0.9	1.0	581.46
4	0.95	1.0	1.1	581.32
5	0.8	1.1	0.9	582.27

表 3-5 遗传算法（GA）超参数实验对比

序号	交叉概率	变异概率	成本 (元/吨)
1	0.57	0.003	586.67
2	0.62	0.017	583.92
3	0.68	0.027	583.47
4	0.73	0.025	584.64
5	0.81	0.012	585.27

表 3-6 蚁群算法（ACO）超参数实验对比

序号	信息素	启发式因子	信息素蒸发系数	成本 (元/吨)
1	0.0001	6	0.4	586.64
2	0.05	12	0	585.87
3	0.01	14	0.3	585.28
4	0.001	8	0.7	586.17
5	0.1	10	0.9	586.27

新型灾变自适应算法（New-GA）参数参考文献^[39]。根据以上实验结果，分别选取各算法最优参数，得到不同烧结配矿优化算法实验结果可视化图如图 3-6 所示。




图 3-6 不同算法效果对比图

从图中可以看出 GA 算法、PSO 算法及 ACO 算法在迭代的中后期陷入局部最优解中，寻优能力降低。经过改进的 APSO、New-GA 及 D-PSO 算法在迭代中期能够快速收敛，并能在局部范围内继续搜索，在迭代后期仍能找到更优解。

表 3-7 不同算法及实际生产数据对比

名称	TFe (%)	SiO ₂ (%)	CaO (%)	MgO (%)	Al ₂ O ₃ (%)	P (%)	S (%)	成本 (元/吨)
人工 配比	56.36	4.88	9.20	2.77	2.32	0.07	0.01	587.58
D-PSO	56.88	4.82	8.98	2.56	2.28	0.069	0.012	578.87
new_GA	56.89	4.85	8.86	2.58	2.31	0.068	0.015	578.98
APSO	56.73	4.75	9.16	2.68	2.29	0.072	0.018	580.35
PSO	56.67	4.79	9.32	2.54	2.36	0.071	0.0058	583.65
GA	55.79	4.72	8.86	2.67	2.34	0.0713	0.015	583.47
ACO	55.87	4.85	9.26	2.72	2.28	0.072	0.02	585.28

选取上述参数调优后的不同算法配矿成本对比结果，以此作为算法对比标准。较大程度的降低了调参偶然性对配矿成本优化的影响，更为准确的反映了不同算法对烧结配

矿成本优化对比的可靠性。选取不同算法在较优调参下的结果进行对比，如表 3-7 所示。

从表 3-7 中可以看出 D-PSO、PSO、APSO、GA、new_GA、ACO 算法计算结果均优于根据人工经验调节的配比，其中 D-PSO 算法较其他几种优化算法，能够得到更优的配比方案，且提高了 TFe 含量。从图 3-7 中也可清晰地看出 D-PSO 算法与其他优化算法相比烧结配矿成本相对较低。



图 3-7 不同优化方法成本对比图

3.5 本章小结

在本章节中针对烧结配料优化问题提出一种基于粒子间隔 D-PSO 算法的烧结配矿优化方法，结合烧结配矿实际生产特点，对 PSO 算法易陷入局部最优解问题，提出了基于粒子间隔的 D-PSO 优化方法，并与标准 PSO 算法、遗传算法（GA）、蚁群算法（ACO）、引入松弛变量 PSO 优化算法（APSO）和文献^[39]中的算法（new-GA），通过钢铁企业烧结过程中的实际烧结配矿数据进行了试验对比，通过上述的数据对比可看出，D-PSO 算法在烧结配矿优化中可有效降低生产成本，同时提高了 TFe 的含量，对企业提高经济效益有良好的指导作用。

4 MOEA/D-DPSO 烧结配矿优化算法

4.1 问题分析

烧结是一个高污染的生产过程，尤其是 SO_2 的排放形成的酸雨给工农业生产和人体健康带来严重的危害和环境污染，因此如何降低硫排放是烧结工艺中的重点关注的一个问题。目前降低硫排放经常采用的措施有两种：

(1) 烧结前脱硫，所谓烧结前脱硫就是在指定烧结配矿方案时，按照规定的 SO_2 的排放量使用低硫矿石、低硫燃料来降低原料中总的硫含量，从源头控制流排放。

(2) 烧结后烟气脱硫，是指对烧结过程中产生的烟气中的硫进行脱除，降低对大气的排放量。

第二种脱硫技术不属于本文讨论的范畴，本文不做讨论。第一种脱硫技术本质是通过优化配矿方案，在保证烧结矿质量的前提下降低硫排放。在第 3 章中，提出了基于粒子间隔的粒子群烧结配矿优化算法，其以成本最低为目标函数，未考虑烧结过程中所产生的有害物质硫 (s) 对环境的污染。基于此，本章建立以成本最低、 s 含量最低的多目标烧结配矿优化模型。

4.1.1 多目标优化

当一个最优解需要权衡两个及以上的目标时，而且这些目标之间存在相互矛盾或制约的关系，那么这个问题成为多目标优化问题。多目标优化问题包含最大化或最小化两种问题。多目标优化问题定义如下（以最小化问题为例）：

$$\begin{cases} \text{Min } F(x) = (f_1(x), f_2(x), \dots, f_n(x))^T \\ s.th_i(x) \geq 0 (i = 1, 2, 3, \dots, p) \\ g_j(x) = 0 (j = 1, 2, 3, \dots, q) \end{cases} \quad (4-1)$$

其中， x 是在寻优判断空间中 m 维特征向量， $F(x)$ 表示 n 个所求目标的互相矛盾或互相有约束关系的目标函数，当 n 的大于 3 时，所求问题就变成了多维空间上的多目标

优化问题。 $h_i(x)$ 、 $g_j(x)$ 为目标问题所形成函数的约束限制条件。由于 $h(x)$ 与 $g(x)$ 的约束作用，使其决定了决策向量 x 的取值区间。

定义 1(Pareto 占优) 当决策变量 x_1 与 x_2 是上述多目标优化问题的可行解,则称 x_1 与 x_2 相比, x_1 是 Pareto 占优(即 x_1 支配 x_2 , 记作 $x_1 > x_2$), 当且仅当

$$\begin{cases} \forall i = 1, 2, \dots, n, f_i(x_1) \leq f_i(x_2) \\ \exists j = 1, 2, \dots, n, f_j(x_1) < f_j(x_2) \end{cases} \quad (4-2)$$

定义 2(Pareto 最优解) 可行域内的一个解 x^* 被称为 Pareto 最优解(非支配解), 当且仅当:

$$\neg \exists x \in \Omega : x > x^* \quad (4-3)$$

定义 3(Pareto 最优解集) 所有 Pareto 最优解集的集合被称为 Pareto 最优解集, 即:

$$P \triangleq \{\neg \exists x \in \Omega : x > x^*\} \quad (4-4)$$

定义 4(Pareto 前言) Pareto 最优解集 P 中的所有 Pareto 最优解对应的目标向量组成的曲线(曲面)被称为 Pareto 最优前言 PF, 即:

$$PF \triangleq \{F(x^*) = (f_1(x^*), f_2(x^*), \dots, f_n(x^*))^T \mid x^* \in P\} \quad (4-5)$$

4.1.2 烧结配矿多目标优化目标函数与约束条件

多目标优化目的是以硫含量和成本为目标的优化。根据钢厂生产需要, 所总结的成本计算方式如下: 其中, i 表示参与配料的原料种类, C_i 表示每种参与配料的原料成本, X_i 表示每种原料的用量。

$$P = \min \sum_{i=1}^n C_i X_i \quad (i = 1, 2, \dots, n) \quad (4-6)$$

烧结矿化学成分含量计算公式如下:

$$\begin{aligned} R &= \sum_{i=1}^n X_i \times (1 - H_2O_i) \times (1 - W_i) \\ M_j &= \frac{\sum_{i=1}^n X_i \times (1 - H_2O_i) \times M_{ij}}{R} \end{aligned} \quad (4-7)$$

R 表示烧结原料在经过脱水与烧损后产生的烧结矿占原烧结配料的百分比。 W_i 表

示每种原料的烧损， H_2O_i 表示第*i*种原料的含水量， M_j 表示烧结矿第*j*种化学成分在烧结矿中的总含量， M_{ij} 表示第*i*个烧结原料中第*j*中化学成分的含量。

在配料过程中，配料人员需保证烧结配矿中的原料配比之和为1。同时为确保模型计算结果符合实际生产要求，对每种原料配比根据人工经验都做了上下限的控制，以确保模型计算结果符合实际生产要求。其约束条件如下所示： $X_{i\min}$ 与 $X_{i\max}$ 分别表示第*i*种烧结原料的配比范围。

$$\begin{cases} \sum_{i=1}^n X_i = 1 \\ X_{i\min} \leq X_i \leq X_{i\max} \end{cases} \quad (4-8)$$

在烧结矿中，硫含量与磷含量对钢铁的性能有不利影响，需要对烧结矿中硫含量与磷含量加以限制。公式如下： s_i 与 p_i 分别表示第*i*中烧结原料中的硫含量与磷含量。

$$\sum_{i=1}^n p_i \times X_i \leq 0.08 \quad (4-9)$$

通过上述分析可以得出，烧结配矿优化模型的目标函数与约束条件如(4-10)、(4-11)所示：

$$\begin{cases} \min \sum_{i=1}^n C_i X_i \\ \min \sum_{i=1}^n s_i \times X_i \end{cases} \quad (4-10)$$

$$s.t. \begin{cases} X_{i\min} \leq X_i \leq X_{i\max} \\ \sum_{i=1}^n p_i \times X_i \leq 0.08 \\ \sum_{i=1}^n X_i = 1 \end{cases} \quad (4-11)$$

4.1.3 MOEA/D 多目标进化算法

MOEA/D 算法首先使用聚合函数形成一组平均权重的转换向量，转换向量的使用将多目标优化问题转换成一系列的单目标优化子问题，该算法首先对转换向量计算欧氏距离，以此形成未来要进行的单目标优化中相应子问题所分派的区间区域*T*大小，将每个子问题的聚合函数进行对比，通过对比关系的量化计算，使其在区域区间内生成新子代，并与其区域区间内的个体进行分别比较，替代结果较差的解。经过上述一系列子问

题的共同合作，达到在可行域内寻找最优帕累托解集的目的。MOEA/D 整体流程如图 4-1 所示。




图 4-1 MOEA/D 算法流程

本文采用契比雪夫(Tchebycheff)聚合函数，其数学表述方式为：

$$\min g^{ws}(x | \vec{\lambda}) = \sum_{i=1}^m \lambda_i f_i(x) \quad (4-12)$$

$$s.t. x \in \Omega \quad (4-13)$$

但 MODA/D 算法欠缺对种群实时状况的反馈能力，易造成算法在寻优时陷入局部最优、粒子分布性不均匀的问题；并且 MODA/E 算法采用的差分进化策略局部搜索能力不强，在算法进化的中后期收敛精度不理想。因此，本文提出一种基于 MOEA/D 的多目标粒子群算法(MOEA/D-PSO)。通过对邻域的更新情况分析构造种群当前状况反馈方式，使用待解决的子问题更新情况结合反向学习模式，形成对应的反向学习方法，并用粒子群进化策略替换差分进化策略。在算法优化过程中，依据种群当前所处状态选择相应的进化策略，从而平衡算法在进化过程中的全局收敛与局部搜索。

4.2 MOEA/D-DPSO 的烧结配矿模型建立

针对 MOEA/D 算法使用差分进化算法导致全局搜索能力弱的问题，本文所提出的 MOEA/D-DPSO 算法主要流程如图 4-2 所示




图 4-2 MOEA/D-PSO 算法流程

4.2.1 基于种群状态的判断机制

在种群进化过程中，由于算法的分布性与收敛性侧重点不相同，因此，需要在种群进化过程中，对种群状态进行状态监控。

在 MOEA/D-DPSO 算法的整体流程中，首先将待解决子问题与权重转换向量一一对应，然后计算各个权重转换向量之间的欧式距离，最后对各个权重转换向量的具体关系根据具体最小优先原则对相应的 T 个权重转换向量进行排序，以此将种群分为 N 个确定的区域区间，确保各个区域区间互相有效配合。在种群更新过程中，新个体 y' 的形成方式依靠本文所提出的 DPSO 算法形成。当新生成的该个体的聚合函数比其所在区间区域的所有个体解都更优异时，那么该区间区域内的所有个体解都会被这个新个体 y' 的聚合函数更新。这样某个种群的更新次数 φ_i 就可以直观地体现出上述一系列子问题的相应种群状态。此时设置一个停止阈值 ε_n ，若区间区域内的更新次数比 ε_n 高时，该子问题处于无序状态，即该子问题对应的邻域处于“全局搜索”状态；否则该子问题处于“局部搜索”状态。其状态判断如公式(4-14)所示。 C 表示在区间区域中出现的所有无序状态的总邻域数， ε_m 表示种群是否为有序状态的阈值，当 C 比 ε_m 大时，认为该种群属于无序种群，即种群目前应进行全局搜索，处于“全局搜索”状态，否则种群处于“局部搜索”状态。其状态更新公式如(4-15)、(4-16)所示。当子问题或种群处于“全局搜索”状态时，采用粒子群进化策略表现效果较好；而反向学习方法对于处于“局部搜索”状态的种群时，效果较为优异。所以，本章在 MOEA/D-DPSO 算法的基础上加入种群状态判断机制。

$$e_q^i = \begin{cases} 0, \varphi_i < \varepsilon_n \\ 1, \varphi_i \geq \varepsilon_n \end{cases} \quad (4-14)$$

$$C = \sum_{i=1}^N e_q^i \quad (4-15)$$

$$E_q = \begin{cases} 0, C < \varepsilon_m \\ 1, C \geq \varepsilon_m \end{cases} \quad (4-16)$$

4.2.2 基于反向学习的进化策略

反向学习策略主要思想是通过求解当前解的反向解集，从反向解集中选择性能较好的解替换性能较差的解，在下次进化过程中，使用所选性能较优解进行进化计算。当算法进化到很多种群都收敛到近似最优解时（有时接近局部最优解）。这时种群的多样性降低、粒子的差异性变小，从而造成算法的局部搜索能力降低。因此，本文在 MOEA/D-DPSO 算法中引入反向学习策略。

反向学习的主要思路是针对某个可行解，首先计算出其反向解，在反向解中选取数个解作为下代学习中待使用的个体。相比于随机选择，反向学习寻优所用的时间更短，易于寻优，且跳出局部最优解的能力更强。反向学习中反向解的计算过程如下：

定义 1 设 $x \in [a, b]$ ， $[a, b] \in R$ ， x' 为 x 的反向解，即：

$$x' = a + b - x \quad (4-17)$$

定义 2 设 $X_i = (x_{i1}, x_{i2}, \dots, x_{in})$ 为当前的可行解， $(x_{i1}, x_{i2}, \dots, x_{in}) \in R$ ，则 X_i 对应的反向解 $\bar{X}_i = (\bar{x}_{i1}, \bar{x}_{i2}, \dots, \bar{x}_{in})$ ，其中 \bar{x}_{ij} 定义如下：

$$\bar{x}_{ij} = a_j + b_j - x_{ij} \quad (4-18)$$

n 为决策空间维度， $x_{ij} \in [a_j, b_j]$ ， $[a_j, b_j]$ 为第 j 维搜索空间的边界，其边界范围从邻域产生，即

$$\begin{cases} a_j = \min(x_{ij}) \\ b_j = \max(x_{ij}) \end{cases} \quad (4-19)$$

若生成的反向解超出边界，则从 $[a_j, b_j]$ 区间内随机生成一个反向解

$$\bar{x}_{ij} = rand(a_j, b_j), a_j < \bar{x}_{ij} < b_j \quad (4-20)$$

4.3 实验对比与分析

选取河北省普阳钢厂 2017 年 3 月 13 日的生产方案作为实验数据。数据主要组成部分如表 3.1 所示。主要包括各原料配比与每种原料中不同化学成分的含量。建立以成本最低、S 含量最低的多目标烧结配矿优化模型，为保证算法的可比性，本实验中对种群规模大小均设置为 100，迭代次数为 100 次。对比算法选择基于 NSGA-II 改进的聚合自适应 NSGA-II (ANSGA-II) 和基于自适应多策略的 MOEA/D 算法(MOEA/D-DE)。

图 4-3 与图 4-4 分别是本文所提算法 MOEA/D-DPSO 与文献^[39]中的 ANSGA-II 与文献^[38]中的 MOEA/D-DE 对比效果图。从图中可以看出 MOEA/D-DPSO 较 ANSGA-II 与 MOEA/D-DE 算法，在全局搜索与局部搜索能力中均较优。




图 4-3 MOEA/D-DPSO 算法与 MOEA/D-DE 算法对比




图 4-4 MOEA/D-DPSO 算法与 ANSGA-II 算法对比

对三种多目标优化算法进行了运行时间的对比，文献^[39]中提到聚合自适应 NSGA-II 算法复杂的较高，运行时间过长。本文所提出的 MOEA/D-DPSO 算法在运行时间上较聚合自适应 NSGA-II 算法降低了 40%，从表 4-1 中可以清楚看出

表 4-1 算法 100 次平均运行时间对比表

算法名称	平均运行时间(min)
聚合自适应 NSGA- II	30
自适应多策略的 MOEA/D	15
MOEA/D-DPSO	18

4.4 本章小结

本章在第 3 章烧结配矿方案成本最低为目标的基础上，将硫含量考虑进去；提出了以成本最低与硫含量最低为目标的多目标优化配矿模型。由于 NSGA-II 算法复杂度较高，运行时间较长，本文采用 MOEA/D 算法来降低运行时间。为弥补 MOEA/D 算法在寻优中后期因粒子差异性降低，易陷入局部的问题，提出了一种基于 MOEA/D 的多目标粒子群算法(MOEA/D-DPSO)。通过实验对比，可以看出 MOEA/D-DPSO 算法较 NSGA-II 算法、自适应 MOEA/D 算法在寻优过程中全局搜索与局部搜索能力均得到了提升。同时在运行时间上较 NSGA-II 算法也得到了降低，提高了算法的运行效率。

5 基于注意力机制—LSTM 算法实现烧结矿质量预测

烧结过程是钢铁生产过程中的首要环节,烧结配料与烧结矿质量检测是烧结过程中保证烧结矿质量稳定性的两个重要环节。为保证烧结矿质量的稳定性,目前普阳钢铁厂会根据配矿方案进行烧结杯实验,通过烧结杯实验对配矿方案进行相应调整,从而保证配矿方案的合理性。但烧结杯实验周期过长且会为企业带来额外的生产成本。针对此问题,本文将通过给定的配矿方案预测烧结矿理化指标,进而优化配矿方案,稳定烧结矿质量;同时避免了烧结杯实验带来的高成本、长周期的问题。

根据第一章所提到的相关工作可以总结出目前烧结矿质量控制方面所遇到的问题有以下 3 点:

- 1) 烧结杯实验周期过长,会造成企业所产生额外的生产成本。
- 2) 由于烧结过程的复杂多变性,浅层网络不能充分挖掘烧结过程的本质规律,不能达到实际生产的要求。
- 3) 由于烧结过程是动态变化的过程,烧结炉中的环境每时每刻都在发生变化,从而造成烧结矿质量的变化。就目前研究来说,未考虑时间维度对烧结矿质量的影响。

实验中,根据烧结厂收集的数据,将烧结配矿方案与理化实验指标一一对应,从而达到预测烧结矿质量的目的。但由于烧结配矿方案中,每种配料的用量变化,从而造成配料方案中存在特定值的缺失。目前,数据处理方法有两种方法:(1)对缺失数据进行补 0 操作,此方法会造成网络在梯度回传时,使得损失消失,造成直接的梯度弥散问题,从而造成网络预测的不稳定性。(2)通过其他值取平均来补全缺失值。此方法在测试中,会导致预测的不准确性。而且训练过程中采用的损失函数为简单的均方误差损失,而训练数据中每轮的缺失数据均是不同的,在训练中随机挑选的数据不同,在最终计算损失时,简单的均方误差则将每一批次数据均以相等权重进行损失计算,其中存在很大的计算失误问题。故针对数据特征,采用加权均方误差方法作为损失函数,结合缺失数据与整体数据之间的权重联系,对均方误差损失进行加权计算,以此得到更为完善的损失评价方式。因此,提出一种改进损失函数的注意力机制-LSTM 的预测方法(A-LSTM)。

5.1 LSTM 与 Attention 的工作原理

5.1.1 LSTM 工作原理

长短时记忆网络（LSTM）结构最早是在 1997 年，由 Sepp Hochreiter 和 Jurgent Schmidhuber 提出的一种特殊的循环体结构；其是拥有“输入门”、“遗忘门”、“输出门”结构的特殊网络结构^[60]。正是因为其拥有三个“门”的特殊结构，使 LSTM 网络具有了长短时记忆的能力；同时也有效地解决了 RNN 度弥散问题和序列的长时依赖问题，原始的 RNN 网络在梯度回传的过程中，传递到较深时刻位置就容易出现梯度消失，因此如果所预测序列是长时序列，消失了的梯度就无法对各个时刻的信息进行模型建立，预测准确性自然会降低。LSTM 神经网络的隐含层内部结构如图 5-1 所示。 X_t 、 Y_t 表示一次输入与输出， W_i 、 W_o 、 W_f 分别表示输入门、输出门和遗忘门的权重， h_n 表示隐含层的状态， h_t 不仅与 X_t 有关与前 t 个隐含层的输出有关。输入门、输出门、遗忘门的计算公式如式(5-1)、式(5-2)、式(5-3)所示。




图 5-1 LSTM 隐含层结构图

$$\begin{cases} i_t = \text{sigmoid}(W_{ix}X_t + W_{ih}Y_{t-1}) + b_i \\ g_t = \tanh(W_{gx}X_t + W_{gh}Y_{t-1}) + b_g \end{cases} \quad (5-1)$$

$$O_t = \text{sigmoid}(W_{ox}X_t + W_{oh}Y_{t-1}) + b_o \quad (5-2)$$

$$f_t = \text{sigmoid}(W_{fx}X_t + W_{fh}Y_{t-1}) + b_f \quad (5-3)$$

5.1.2 注意力机制的工作原理

注意力机制在深度学习中的应用是在 2015 年, Kyunghyun Cho 等人在文献^[62]中, 引入了 Attention Mechanism 来解决传统的 Seq2Seq 模型对输入序列 X 缺乏区分度问题提出, 此后开始了广泛的应用。

注意力机制是一种用于提升基于 RNN 的编码+解码的模型机制, 广泛应用于机器翻译、数据预测、语音识别、图像标注等很多领域, Attention 应用如此广泛的原因是因为其赋予了模型增强辨认的能力。在数据预测中, 将其与 LSTM 序列模型有效结合, 注意力机制模块提取特定关系的特征子序列, 将有特定关系的特征子序列进行 LSTM 序列模型预测训练。利用注意力机制获取数据序列细粒度特征, 利用 LSTM 对获取到的细粒度特征进行粗粒度的提取, 使用特定序列粗细粒度结合的方式, 可有效提高数据相关性预测结果。

在对烧结矿质量进行预测中, 基于注意力机制与 LSTM 结合的预测流程如下:

首先定义一个条件概率,

$$P(y_i | y_1, y_2, \dots, y_{i-1}, X) = g(y_{i-1}, s_i, c_i) \quad (5-4)$$

其中, s_i 是编码器中 LSTM 在 i 时刻的隐状态, 如公式(5-5)中所示, 其计算公式为:

$$s_i = f(s_{i-1}, y_{i-1}, c_i) \quad (5-5)$$

向量 c_i 采用加权的方式确立, 其表达式如公式(5-6)所示:

$$c_i = \sum_{j=1}^{T_x} a_{ij} h_j \quad (5-6)$$

其中, i 表示编码器端的第 i 个维度的配料数据, h_j 表示编码器端的第 j 个维度的数据隐向量, a_{ij} 表示编码器端的第 j 个数据隐向量与解码器端的第 i 个输出维度预测值之间的权值, 即源端第 j 个维度的输入配料数据对目标端第 i 个输出预测的影响程度, a_{ij} 的计算公式如公式(5-7)所示:

$$a_{ij} = \frac{\exp(e_{ij})}{\sum_{k=1}^{T_x} \exp(e_{ik})} \quad (5-7)$$

$$e_{ij} = a_{ij}(s_{i-1}, h_j) \quad (5-8)$$

在公式(5-8)中, e_{ij} 表示一个数据影响模型, 用于确定编码器端的位置 j 的输入配料维度 a_{ij} , 对于解码器端的第 i 个输出的影响程度, 即, 表示解码器端生成位置 i 的输出预测值时, 受编码器端的索引 j 的输入配料维度影响程度。数据影响模型 e_{ij} 的生成方式有多种, 当生成方式不同时, 所表示的注意力模型也有相应不同, 而相对较简单的并应用广泛的数据影响模型是点乘乘积矩阵, 即采用矩形相乘的形式将目标端的输出状态 h_i 与源端的输出状态相乘。常见的数据影响计算方式如下:

$$score(h_i, \bar{h}_s) = \begin{cases} h_i^T \bar{h}_s \\ h_i^T W_a \bar{h}_s \\ v_a^T \tanh(W_a [h_i, \bar{h}_s]) \end{cases} \quad (5-9)$$

其中, $score(h_i, \bar{h}_s) = a_{ij}$ 表示源端与目标关系的影响程度。故常见的数据影响关系计算方式有, 点乘 (Dot product), 权值网络映射 (General) 和 concat 映射几种方式。在对配料数据的预测优化中, 由于输入配料数据中有很多的 0 值, 若选用点乘或权值网络映射的方式进行数据影响计算, 那将会带来更多的 0 值, 使网络更难以收敛。若选用 concat 映射, 那么每次输入的配料数据将会对下次产生较大的影响, 若从网络训练的全局看, 这样的处理方式可有效减小 0 值在训练数据中的占比, 从而以更为柔和的方式对 0 值进行处理。因此本文的数据影响计算方式选用 concat 映射。

5.2 基于注意力机制的 LSTM 烧结矿质量预测模型

5.2.1 烧结矿质量预测模型的建立

将注意力机制与 LSTM 相结合, 可有效改善 LSTM 的特征序列冗余问题。采用注意力机制对 LSTM 进行改进。注意力机制将在 LSTM 在训练的过程中, 关注更多的缺失特定数据之外的数据, 而抑制数据中对训练无更大贡献的冗余数据。从另一层次上加强了对缺失数据的考虑, 可使模型预测更为精准。原因在于注意力机制较大程度排除了冗余数据的影响, 使得对特殊点的拟合程度提高。注意力机制与 LSTM 相结合的算法

结构如图 5-2 所示。主要分为四个部分：（1）数据预处理：将每两小时采样所得理化指标数据与其烧结配矿方案进行对应；由于数据大小不同，其取值范围也不同，因此在进行 LSTM 训练前首先进行归一化操作；将 5.4 节中整理的数据集拆分为训练集与测试集。（2）注意力机制层：从原始数据中以两小时为间断点截取数据作为 attention 层的输入，从而降低缺失数据对模型的影响。（3）LSTM 层：前一 LSTM 单元的输出作为后一单元的输入。（4）输出层：LSTM 的隐含层进行输出。




图 5-2 注意力机制与 LSTM 相结合算法结构图

5.2.2 加权均方误差损失

在数据预测中，其最终的目的是进行数据点的回归，而均方误差（MSE）则是数据回归预测的有效评价方式，均方误差公式如下：

$$J(\theta) = \frac{1}{2m} \sum_{i=1}^m (h_{\theta}(x^{(i)}) - y^{(i)})^2 \quad (5-10)$$

其中 $h_{\theta}(x^{(i)})$ 表示数据预测结果， $y^{(i)}$ 表示真实数据， m 表示数据总量。 $1/2$ 是一个常量，这样是为了在求梯度的时候，二次方乘下来就和这里的 $1/2$ 抵消了，自然就没有多余的常数系数，方便后续的计算，同时对结果不会有影响。 h 是预测函数，根据每一个输入 x ，根据 θ 计算得到预测的 y 值，即

$$h_{\theta}(x^{(i)}) = \theta_0 + \theta_1 x_1^{(i)} \quad (5-11)$$

模型相对于测试集的均方误差是测试集中所有实例的预测误差均方的均值。预测误

差是实例的真实值和预测值之差。根据损失函数看到，损失函数中的变量有两个，在 LSTM 的反向传播中，均方误差的反向传播是一个多变量的梯度下降问题，求解出代价函数的梯度，也就是分别对两个变量进行微分。

$$\nabla J(\theta) = \left\langle \frac{\partial J}{\partial \theta_0}, \frac{\partial J}{\partial \theta_1} \right\rangle \quad (5-12)$$

$$\frac{\partial J}{\partial \theta_0} = \frac{1}{m} \sum_{i=1}^m (h_{\theta}(x^{(i)}) - y^{(i)}) \quad (5-13)$$

$$\frac{\partial J}{\partial \theta_1} = \frac{1}{m} \sum_{i=1}^m (h_{\theta}(x^{(i)}) - y^{(i)}) x_1^i \quad (5-14)$$

从上述推导可以看出，当损失函数确定为均方误差损失后，每一次的梯度更新则与每一批次的全部数据量都将有关系，而烧结矿预测数据中，每一轮的数据均有不同维度的缺失，而这种缺失并不是由于数据收集失误导致，而是真实配料经验数据得到。当对这样的数据进行 LSTM 预测训练时，单一的均方误差损失则会将所有的数据都纳入特征序列范畴，而缺失为 0 的数据对训练起不到任何作用，但损失计算的却是全部数据的损失结果。这种损失函数的设置将导致，训练过程损失收敛难度加大，因为每一批次所取的数据缺失值维度的种类、数量均不一样，而损失计算时则将这一批次的全部数据考虑在内。这种情况就导致了每次训练的参数在刚要稳定时，下一轮数据放入后，参数又将有极大的概率出现震荡，训练损失极难收敛。实际上，在真实的调参训练实验中，也出现了这种训练难以收敛的情况，图 5-3 为基于 LSTM 的烧结矿预测方法实验训练中 loss 无法收敛的可视化结果，这种结果在训练中占据了极大的比例。




图 5-3 训练过程无法收敛的可视化结果

根据上述分析，对损失函数进行改进，设某一批缺失数据的数据量为 n ，对均方误差损失进行加权平均后的损失函数为：

$$J(\theta) = \frac{n}{2m} \sum_{i=1}^m (h_{\theta}(x^{(i)}) - y^{(i)})^2 \quad (5-15)$$

梯度下降过程中，两个梯度的求解变为：

$$\frac{\partial J}{\partial \theta_0} = \frac{n}{m} \sum_{i=1}^m (h_{\theta}(x^{(i)}) - y^{(i)}) \quad (5-16)$$

$$\frac{\partial J}{\partial \theta_1} = \frac{n}{m} \sum_{i=1}^m (h_{\theta}(x^{(i)}) - y^{(i)}) x_1^i \quad (5-17)$$

由推导可知，此损失有效的将缺失数据量加权在损失计算中，从理论角度分析，当每一批次的数据进入网络训练时，损失计算会根据缺失数据量确定梯度更新的大小，使梯度变化与缺失数据变化形成有效统一。从而更好的使损失收敛，使模型拟合泛化性提高。

5.3 实验结果对比与分析

5.3.1 实验数据与评价指标

本文实验数据为河北普阳钢铁企业 2017 年 1-12 月份的实际烧结配矿与每两小时采集的理化试验指标数据。每条数据中包含的信息有：各个配料的含量、理化试验得出的 FeO、SiO₂、CaO 等指标含量。首先按照 5.3 节中所提的数据预处理方法对原始数据进行处理，再按照 3:1 的比例划分，也就是说前 9 个月的数据作为训练数据，后 3 个月的数据作为测试数据。数据输入时进行归一化处理，输出时进行反归一化处理。

本文选取两种评价指标，具体定义如下：

(1) 均方根误差：真实值与预测值之间的误差的平方均值（Root Mean Square Error, RMSE），公式为：

$$\text{RMSE} = \sqrt{\frac{1}{H} \sum_{h=1}^H (y - y_t)^2} \quad (5-18)$$

(2) 确定性相关系数（R² score）：该值可对所生成模型的预测效果进行衡量，数值越高，表示模型预测性能更佳，计算公式如下所示：

$$R^2 = 1 - \frac{\sum_{h=1}^H (y_t - \bar{y})^2}{\sum_{h=1}^H (y - \bar{y})^2} \tag{5-19}$$

其中， y 表示数据的真实值， y_t 表示 t 时刻的 y 的预测值， \bar{y} 表示原始数据的均值。

5.3.2 实验结果与分析

将提出的 A-LSTM 烧结矿质量预测方法与传统 LSTM 网络、应用较为广泛的 BP 神经网络、深度置信网络（DBN）、Elman 网络进行了对比。为体现算法对比有效性，最大可能的降低调参偶然性，对以上多种算法进行超参数实验对比。对比结果如表 5-1 至 5-3 所示。

表 5-1 本文提出的 A-LSTM 烧结矿质量预测方法参数对比

序号	注意力深度	LSTM 步长	学习率	RMSE
1	1	2	0.001	0.0988
2	2	5	0.01	0.0831
3	3	7	0.00001	0.0702
4	4	9	0.0001	0.0789

上述超参数选取的是经过多次实验得到较优结果的参数，从参数对比可以看出，当注意力深度为 3，LSTM 步长为 7，学习率为 0.00001 时，均方根误差最小。

表 5-2 传统 LSTM 烧结矿质量预测方法参数对比

序号	LSTM 步长	学习率	RMSE
1	2	0.01	0.2305
2	4	0.0001	0.1062
3	6	0.001	0.1653
4	8	0.1	0.3764

经过多次实验得出，传统 LSTM 在步长为 4，学习率为 0.0001 时，所得结果均方

误差最小。

表 5-3 BP 神经网络烧结矿质量预测方法参数对比

序号	隐含层数	损失函数	RMSE
1	1	平均绝对误差	0.2305
2	3	交叉熵	0.1842
3	4	均方误差	0.2145

从表 5-3 可以看出 BP 网络在隐含层为 3，损失函数为交叉熵时，均方误差较小。深度置信网的参数为文献^[37]中采用的参数；Elman 网络设置参数为文献^[36]中的参数设置。图 5-4 至 5-6 是不同算法对烧结矿中 FeO 、 CaO 、 FeO 含量的预测对比实验图。




图 5-4 SiO_2 含量预测对比图




图 5-5 CaO 含量预测对比图




图 5-6 FeO 含量预测对比图

从可视化曲线中可以直观地看出，A-LSTM 烧结矿质量预测方法较 LSTM、BP、Elman、DBN 等在烧结矿质量预测应用较为广泛的方法，A-LSTM 预测结果相对误差较低。不同预测方法对比如表 5-4 所示。

表 5-4 不同预测方法的结果对比

预测方法	RMSE	R^2	Acc
A-LSTM	0.0702	0.754	0.927
LSTM	0.0942	0.586	0.908
BP	0.1062	0.465	0.854
DBN	0.0885	0.541	0.893
Elman	0.0824	0.448	0.886

由表 5-4 中的各模型预测结果的评价指标可以发现：

- （1）BP 网络与 Elman 浅层网络在一定程度上获取了烧结过程的规律，但不能充分挖掘到烧结过程的本质规律。在 RMSE、 R^2 和准确率表现均较差，对于未知样本的预测效果相对较低。
- （2）DBN 与 LSTM 算法相于浅层网络结构来说，能够挖掘到更多烧结过程的本质规律，但缺失数据对网络的影响相对较大。
- （3）本文所融合了不同粒度特征，建立了基于注意力机制的 LSTM（A-LSTM）烧结矿质量预测方法，在 RMSE 与 R^2 两个指标上表现良好。对 FeO 、 CaO 、 SiO_2 的预

测误差均在 $(-0.2, +0.2)$ 之间，符合实际生产要求。

5.4 本章小结

针对目前钢铁企业传统烧结块质量检测方法，本文提出一种基于注意力机制的 LSTM (A-LSTM) 烧结矿质量预测方法。通过注意力机制提取到细粒度特征，再通过 LSTM 网络挖掘包含更多信息的粗粒度特征，实现对烧结矿质量的准确预测。针对数据缺失造成的损失不能收敛问题，提出加权均方误差的计算方式。烧结矿配料澳混合粉、块矿混合粉、铁皮、麦克粉配比等方面建立模型对 FeO 、 SiO_2 、 CaO 等含量进行预测。实验结果表明，A-LSTM 模型在训练过程中容易收敛，在测试过程中最大程度上摆脱了数据缺失维度对预测模型的影响。模型的预测值与实际值之间的误差在 $(-0.2, +0.2)$ 之间，预测结果更为精准，符合烧结过程的生产要求，对烧结过程的工艺调整有深刻指导价值。

6 总结与展望

6.1 总结

烧结过程是一个非线性的物理与化学变化，烧结矿的质量对高炉炼铁等后续操作有直接的影响，而烧结配矿与烧结矿质量预测是控制烧结矿质量的两个重要部分，本文针对烧结过程中烧结配矿优化与烧结矿质量预测进行研究，主要包括两部分内容：

1、提出了一种基于粒子间隔 D-PSO 的烧结配矿算法，建立了以成本最优为目标的配矿模型。针对 PSO 算法已陷入局部最优问题，将粒子与当前最优解的距离融入到粒子速度更新中，使粒子具有依据距离自主判断的能力，从而解决标准 PSO 易陷入局部最优的问题。以烧结配矿的实际生产数据作为试验数据，将人工配比方案与 D-PSO 算法、标准 PSO 算法、遗传算法、蚁群算法计算所得方案进行了对比分析，实验结果表明，D-PSO 算法在符合烧结配矿生产要求的前提下，降低了企业的生产成本，同时提高了烧结矿中铁含量，降低了硫、磷等有害成分的含量。

2、提出了一种基于 MOEA/D 的多目标粒子群烧结配矿优化算法(MOEA/D-DPSO)，建立了以硫含量和成本指标最低的多目标配矿模型。该算法将提升了全局收敛能力的 D-PSO 算法与 MOEA/D 结合，并引入反向学习策略，平衡了收敛性和分布性，从而平衡了算法在进化过程中的全局收敛能力和局部搜索能力。实验结果表明，该算法相比于人工配矿方案，在符合烧结配矿生产要求的前提下，有效降低了硫含量和成本。此外，相比于 MOEA/D 与多策略机制改进的 MOEA/D 算法，MOEA/D-DPSO 有效提升了算法全局收敛能力，较为有效的防止其陷入局部最优。

3、提出一种基于注意力机制—LSTM 的烧结矿质量预测算法，以此建立了烧结矿质量预测模型。在 LSTM 网络的基础上，利用注意力机制思想，通过权重的再分配，关注更多的缺失数据之外的数据，而抑制数据中对训练无更大贡献的冗余数据。从另一层次上加强了对缺失数据的考虑，并对 LSTM 中损失函数的计算方式的改进，将每轮输入数据中缺失值占总体的比重考虑进去，减少损失函数在训练过程中的震荡，使模型预测更为准确。通过实验结果表明，增加注意力机制的 LSTM 预测方法较 LSTM 预测方法，预测准确率提高了 1.9%。

6.2 展望

烧结过程是钢铁生产中的第一步工序，也是最重要的一步工序。其直接决定着高炉炼铁等后续工作的生产效率，以及钢铁生产过程中的成本问题。本文虽针对烧结过程中较为重要的两个环节进行了相应的研究，但其在以后还需有以下方面的深入研究：

1、在烧结配矿优化研究中，本文针对降低成本与硫排放量问题进行了研究。但从烧结矿质量的整体和环境保护的角度出发，还应对磷、碳等污染气体的排放进行相应的约束与控制，从而达到及保护环境、降低生产成本的效果。这也是在烧结配矿方面，一直不断追求的方向。

2、在烧结矿质量预测研究中，本文从时间维度考虑，采用基于 A-LSTM 预测方法对烧结矿质量进行了预测，但由于采集到的烧结过程中的工艺参数较少，在以后的研究中，将更多影响烧结的因素考虑进去，从而提高烧结的精度。

参考文献

- [1] 李勇,吴敏,曹卫华,等.基于线性规划和遗传-粒子群算法的烧结配料多目标综合优化方法[J].控制理论与应用,2011, 28(12):1740-1746.
- [2] 余其红.铁矿石资源多样化条件下烧结矿配矿优化研究[D].武汉科技大学,2014.
- [3] 张寿荣.中国炼铁企业的前景[J].中国冶金,2016,26(10):7-8.
- [4] 张东宏.配料工艺改进对烧结矿的影响[J].中国金属通报,2017(2):47-48.
- [5] 李勇.烧结混合料制备过程智能集成优化控制策略及其工业应用[D].中南大学,2012.
- [6] 王伟,陈畏林,贾斌,等.基于线性规划和神经网络的优化烧结配料系统开发[J].烧结球团,2006, 31(1):27-30.
- [7] 唐庆利,张建良,李克江,等.烧结配料优化方法及算法对比分析[J].中国冶金, 2017, 27(5):13-18.
- [8] 常雨芳,王粟,黄文聪,等.线性规划问题计算机求解方法研究[J].软件导刊, 2012, 11(9):25-27.
- [9] 周景生.应用线性规划方法进行烧结配料计算[J].烧结球团,1987(5):6-10.
- [10] 王道群.线性规划在烧结矿配料中的应用[J].冶金丛刊,2005,15(3):19-22.
- [11] 余鹤元.线性规划方法在烧结矿配料中的应用[J].现代冶金,1988(1):59-62.
- [12] 贾彦忠,王书瑞,周振庄,等.烧结配料优化利用研究[J].河北冶金,1995(3):15-18.
- [13] 孟福真.不确定性矿配问题的优化方法研究[D].中南大学,2009.
- [14] 向婕.铁矿石烧结过程智能集成优化控制技术及其应用研究[D].中南大学,2010.
- [15] 王家军,张晓冬,朱进,等.采用线性规划法的烧结原料配料优化[J].河北冶金,2017(2):35-37.
- [16] Holland J H. Adaptation in natural and artificial systems[M]. MIT Press,1992.
- [17] 侯武民,张韬.基于遗传算法的烧结配料优化方法[J].数字技术与应用, 2013(1):118-119.
- [18] 李智,姚驻斌.免疫遗传算法在烧结矿配料优化中的应用[J].上海金属,2004, 26(6):23-28.
- [19] 杨钊,李智.基于遗传算法的烧结配料优化[J].武汉轻工大学学报,2011, 30(3):54-57.
- [20] 纪钟晨,马西武,钟志洁.遗传算法和线性规划在烧结配矿管理模型中的应用分析[J].冶金管理,2016(11):35-37.
- [21] 李凯斌.智能进化优化算法的研究与应用[D].浙江大学, 2008.
- [22] Eberhart R C. Swarm intelligence[J].Nature-Inspired and Innovative Computing.2001:187-291.
- [23] 吴敏,丁雷,曹卫华,等.基于混合粒子群算法的烧结配料优化[J].信息与控制,2008, 37(2):242-246.
- [24] 李智,姚驻斌,等.粒子群算法在烧结矿配料优化中的应用[J].有色金属工程,2005, 57(3):51-54.

- [25] Dorigo M, Maniezzo V, Colorni A. Ant system: optimization by a colony of cooperating agents[J].IEEE Transactions on Systems Man & Cybernetics Part B Cybernetics A Publication of the IEEE Systems Man & Cybernetics Society,1996,26(1):29.
- [26] Bonabeau E, Dorigo M, Theraulaz G. Inspiration for Optimization from Social Insect Behavior[J].Nature,2000,406(6791):39-42.
- [27] 徐伟,王荣成,刘红芳,等.蚁群算法在烧结混匀矿配料中的应用[J].冶金自动化, 2007,31(6):12-15.
- [28] 刘红芳,王荣成,徐伟,等.蚁群算法在杭钢烧结混匀矿等 SiO₂ 等 TFe 配料中的应用[J].烧结球团, 2007, 32(1):33-38.
- [29] Liu X, Feng H. & Chen, L. Arab J Sci Eng (2018) 43: 5003. <https://doi.org/10.1007/s13369-018-3115-4>.
- [30] Zhang, J., Xie, A. & Shen, F. Multi-Objective Optimization and Analysis Model of Sintering Process Based on BP Neural Network. J. Iron Steel Res. Int. 14, 1–5 (2007) doi:10.1016/S1006-706X(07)60018-1.
- [31] Wang, Y., Ma, J., Gui, W. et al. Multi-objective intelligent coordinating optimization blending system based on qualitative and quantitative synthetic model. J Cent. South Univ. Technol. 13, 552–557 (2006) doi:10.1007/s11771-006-0086-5.
- [32] Shen, X., Chen, L., Xia, S. et al. Iron ores matching analysis and optimization for iron-making system by taking energy consumption, CO₂ emission or cost minimization as the objective. Sci. China Technol. Sci. 60, 1625–1637 (2017) doi:10.1007/s11431-017-9072-9.
- [33] Xiao-Xia C, Min W, Wei-Hua C, et al. A BC-PSO algorithm of multi-objective and fuzzy satisfactory optimization for sintering burden[C]//Proceedings of the 31st Chinese Control Conference. IEEE, 2012: 7576-7581.
- [34] Ping D, Min W, Chenhua X. Coordinating Control Based on Multi-objective Intelligent Optimization for the Overall Lead-zinc Sintering Process[C]//2007 Chinese Control Conference. IEEE, 2007: 249-253.
- [35] Senapati N P, Tripathy S, Samantaray S. A multi-objective optimization using a combined approach of principal component analysis and TOPSIS during electric discharge machining of H-11 die steel using P/M processed Cu-Cr-Ni metal matrix composite[C]//2016 International Conference on Electrical, Electronics, and Optimization Techniques (ICEEOT). IEEE, 2016: 1207-1212.

- [36] Jinni Z , Qianyi Z , Yan C , et al. A multi-objective optimization method and application to stacker-reclaimer job[C]// Control Conference. IEEE, 2012.
- [37] Zhang Q , Li H . MOEA/D: A Multiobjective Evolutionary Algorithm Based on Decomposition[J]. IEEE Transactions on Evolutionary Computation, 2008, 11(6):712-731.
- [38] 耿焕同,周山胜,韩伟民,et al.基于自适应进化策略的 MOEA/D 算法[J].计算机工程与设计,2019, 40(04):213-220.
- [39] 王策.炼铁烧结配矿优化模型及其应用研究[J].石家庄:河北经贸大学,2019.
- [40] 韩庆虹,金永龙,张军红.BP 网络在烧结矿质量预测中的初步应用[J].烧结球团, 2005,30(1):20-22.
- [41] 张军红,谢安国,沈峰满.烧结矿质量预测的 BP 网络模型 [J]. 辽宁科技大学学报, 2001,24(6):406-408.
- [42] 刘颂,吕庆,刘小杰,et al.基于混匀矿烧结基础特性配矿专家系统的开发与应用[J]. 烧结球团, 2017(2).
- [43] Li Z, Fan X, Chen G, et al. Optimization of iron ore sintering process based on ELM model and multi-criteria evaluation[J]. Neural Computing and Applications, 2017, 28(8): 2247-2253.
- [44] 宋强.基于 BP 神经网络和灰色神经网络的烧结矿化学成分预测模型研究[D].昆明理工大学,2012.
- [45] 牛江峰.基于灰色理论的烧结矿质量预测智能优化研究[J].黑龙江冶金,2016.
- [46] 汪清瑶,刘琼.基于 Elman 神经网络的烧结矿质量在线预测研究[J].仪表技术与传感器,2017(10).
- [47] 袁致强.基于深度置信网络的烧结矿化学成分预测模型研究[D].武汉科技大学,2015.
- [48] 王斌,袁致强,张良力.基于深度置信网络的烧结矿化学成分预测方法[P],2019 CN108388762A.
- [49] 段大高,赵振东,梁少虎,et al.基于 LSTM 的 PM2.5 浓度预测模型[J].计算机测量与控制,2019 27(03):221-225.
- [50] Broni-Bedaiko C, Katsriku F A, Unemi T, et al. El Niño-Southern Oscillation forecasting using complex networks analysis of LSTM neural networks[J]. Artificial Life and Robotics, 2019, 24(4): 445-451.
- [51] 彭燕,刘宇红,张荣芬.基于 LSTM 的股票价格预测建模与分析[J].计算机工程与应用,2019(11).
- [52] Cai S., Feng X., Deng Z., Ming Z., Shan Z. (2018) Financial News Quantization and Stock Market Forecast Research Based on CNN and LSTM. In: Qiu M. (eds) Smart Computing and Communication. SmartCom 2018. Lecture Notes in Computer Science, vol 11344. Springer, Cham.
- [53] 李梅,宁德军,郭佳程.基于注意力机制的 CNN-LSTM 模型及其应用[J].计算机工程与应用, 2019.

- [54] Araya I.A., Valle C., Allende H. (2019) LSTM-Based Multi-scale Model for Wind Speed Forecasting. In: Vera-Rodriguez R., Fierrez J., Morales A. (eds) Progress in Pattern Recognition, Image Analysis, Computer Vision, and Applications. CIARP 2018. Lecture Notes in Computer Science, vol 11401. Springer, Cham
- [55] 王露潼,王红,宋永强,王倩.基于 FT-LSTM 模型的临床事件诊断序列预测研究[J/OL].计算机应用研究:1-7[2020-05-05].<https://doi.org/10.19734/j.issn.1001-3695.2019.04.0192>.
- [56] Wang X.,Chen H.,Li Z., Zhao Z.(2018) Unrest News Amount Prediction with Context-Aware Attention LSTM. In: Geng X., Kang BH. (eds) PRICAI 2018:Trends in Artificial Intelligence. PRICAI 2018.Lecture Notes in Computer Science,vol 11013.
- [57] Gallardo-Antolín A., Montero J.M. (2019) External Attention LSTM Models for Cognitive Load Classification from Speech. In: Martín-Vide C., Purver M., Pollak S. (eds) Statistical Language and Speech Processing. SLSP 2019. Lecture Notes in Computer Science, vol 11816.
- [58] Shuang K., Ren X., Guo H., Loo J., Xu P. (2019) Effective Strategies for Combining Attention Mechanism with LSTM for Aspect-Level Sentiment Classification. In: Arai K., Kapoor S., Bhatia R. (eds) Intelligent Systems and Applications. IntelliSys 2018. Advances in Intelligent Systems and Computing, vol 869.
- [59] Dey K., Shrivastava R., Kaushik S. (2018) Topical Stance Detection for Twitter: A Two-Phase LSTM Model Using Attention. In: Pasi G., Piwowarski B., Azzopardi L., Hanbury A. (eds) Advances in Information Retrieval. ECIR 2018. Lecture Notes in Computer Science, vol 10772.
- [60] Wang X., Chen G. (2017) Dependency-Attention-Based LSTM for Target-Dependent Sentiment Analysis. In: Cheng X., Ma W., Liu H., Shen H., Feng S., Xie X. (eds) Social Media Processing. SMP 2017. Communications in Computer and Information Science, vol 774.
- [61] 科特曼,H,金心.现代烧结用粉矿和精矿的质量要求[J].烧结球团,2014(6):38-46.3.
- [62] Cho,Kyunghyun, van Merrienboer,Bart, Gulcehre,Caglar. Learning Phrase Representations using RNN Encoder-Decoder for Statistical Machine Translation[J]. Computer Science, 2014.

作者简介

姓名:	武晓婧	民族:	汉族
性别:	女	出生日期:	1993.09.15
籍贯:	河北石家庄	最后学历:	硕士研究生
专业:	计算机应用技术	毕业院校:	河北经贸大学

学习经历:

2012 年 9 月至 2016 年 6 月 衡水学院 计算机科学与技术 攻读学士学位

2017 年 9 月至 2020 年 6 月 河北经贸大学信息技术学院 计算机应用技术专业
攻读硕士学位

攻读学位期间取得的科研成果:

1. Lihui Sun, Xiaojing Wu, Ce Wang et al. Research on the optimization algorithm of sintering ingredients[J]. Iop Conference, 2018, 382. (EI 收录)
2. Lihui Sun, Xiaojing Wu. Application of particle spacing based PSO algorithm in sintering batching[J]. LNEE, 2019, 978. (Springer 收录)
3. 孙立辉, 武晓婧. 基于注意力机制—LSTM 算法的烧结矿质量预测[J]. 软件导刊, 2020.(已录用, 10 或 11 期出刊, 国家级期刊)

致 谢

研究生三年时光，转瞬即逝。在即将毕业之际，对校园的不舍之情愈加明显，因为这里有悉心教导我的老师，有朝夕相处的朋友。正是有有他们的陪伴，我在这里度过了欢乐、充实和收获的三年。

在这三年中，我最要感谢的是我的导师孙立辉教授。他严谨的学术态度和渊博的专业知识，让我受益匪浅。孙老师虽工作繁忙但也从未忘对我的论文进行细致的指导，从论文的选题、研究的方向到最终论文的书写，在论文的各个阶段都对倾注了导师的心血，不辞辛劳地给予了精心的指导与修改。论文能够顺利完成，与孙老师的谆谆教导与严格要求是分不开的。三年的教导，为我以后的道路奠定了基础，让我受益终身。

在校学习期间，还曾得到董兆伟教授、王素贞教授、和志强教授、曾文献教授、翁小清教授、王建军教授、王卫红教授和张荣梅教授的谆谆教诲和热心帮助。无论是在专业知识的讲授还是认识的解惑，老师们都给予我很大的帮助。我们的顺利毕业离不开老师们的无私奉献，我将不忘师恩，铭记于心。

我还要感谢身边热心善良的同学们，三年的时光，我们一起互相帮助，互相关心，三年的时间培养了我们深厚的友谊，你们是我前进路上的后盾，愿我们友谊长存。

最后，我还要感谢我的家人，感谢我的父母辛勤劳动，为我提供优越的生活环境，无论我遇到什么困难，他们都用最无私最关切的爱鼓舞着我，家人永远是最温暖的港湾，他们的支持与包容，让我健康成长，是我奋斗路上的支持与动力。



河北经贸大学研究生学院监制